



UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD POLITÉCNICA

Enrutamiento y Asignación de Espectro en Redes Ópticas Elásticas

Una formulación ILP y un Algoritmo Genético Multi-objetivo

INGENIERIA EN INFORMATICA

TRABAJO FINAL DE GRADO

Autor:

Ysapy Mimbi Ortiz Amarilla

Tutor:

D.Sc. Diego P. Pinto-Roa

SAN LORENZO - PARAGUAY

2017

Dedicatoria

A mis papás, a mis hermanas y a mi abuela querida.

Ysapy Mimbi.

Agradecimientos

A mis papás y a mi tutor, por la guía, paciencia e incentivo durante todo el proceso.

A la empresa Software Natura por su apoyo.

A mis compañeros y amigos por la paciencia.

Abstract

The increasing network traffic and the need to expand the capacity and performance of transmissions are achieved through the use of optical fiber. The current working of the transmission networks are based on Wavelength Division Multiplexing (WDM). This technology has the ability to transport, route and assign multiple channels on a single optical fiber that supports the transmission of different wavelengths. Here, each channel is assigned to a single type of traffic, which results in resource underutilization when channel does not operate at maximum capacity. Consequently, Elastic Optical Networks (EONs) emerge as an alternative to WDM networks to maximize the use of the bandwidth of the optical fiber based on flexible spectral grid. This enables the allocation of variable bandwidth to optical channels with low-speed traffic, resulting in an increased efficiency of the spectrum. In WDM networks, the routing and wavelength assignment (RWA) algorithm seeks a physical path through the network and assign a wavelength for information transport between source and destination nodes. The routing and spectrum assignment (RSA) is an extension of RWA in EONs where the selected wavelength/spectrum must meet physical layer constraints. The RSA and RWA are NP-hard problems. The scope of this work is addressing the RSA problem as a multi-objective optimization problem, in this context, we propose a Multi-objective Integer Linear Programming (MOILP) model as an exact solution and a Multi-objective Genetic Algorithm (MOGA) as an approximation approach that calculate the optimal routing and spectrum allocations for a set of static unicast requests with different bandwidth requirements. The MOILP and MOGA seek to optimize the total cost of resource used, the maximum spectrum and quality of service defined by the distance between source and destination node, by weighed sum. Performed testing shows promising MOGA results with respect to the proposed MOILP and a Genetic Algorithm (GA), this last one was proposed by the stated-of-the-art. In small networks, MOGA solutions are similar to optimal MOILP solutions. In medium and large networks, the MOILP can not calculate solutions because it is a non scalable approach. In anhothor hand, MOGA gets good solutions in comparison to those obtained by the GA. Finally this work presents results about how the Algorithms performance change when the number of shortest path are modified.

Resumen

Las transmisiones actuales de redes, están basadas en la Multiplexación de División de Longitud de Onda (WDM, *Wavelength Division Multiplexing*). Esta tecnología tiene la habilidad de transportar, enrutar y asignar múltiples canales en una sola fibra óptica que soporta la transmisión de diferentes longitudes de onda. Aquí, cada canal es asignado a una sola transmisión, lo que resulta en el uso ineficiente del canal cuando no opera a su máxima capacidad. Consecuentemente, un nuevo paradigma, el de las Redes Ópticas Elásticas (EON, *Elastic Optical Network*), emerge como una alternativa a las redes WDM para maximizar el uso del ancho de banda de la fibra basado en la Grilla de Espectro Flexible (Flexi-grid). El Flexi-grid permite la asignación de ancho de banda variable a los canales ópticos, resultando en un incremento de eficiencia del espectro. En las redes WDM, el algoritmo de Enrutamiento y la Asignación de Longitudes de Onda (RWA, *Routing and Wavelength Assignment*) busca una ruta a través de la red y asigna una longitud de onda para el transporte de la información entre el nodo origen y el nodo destino, cumpliendo las restricciones propias de las redes ópticas. En las redes EON, se introduce el concepto de Ranuras de Frecuencia (FS, *Frequency Slots*) que representan las divisiones del Flexi-grid y se plantea un nuevo problema, el Enrutamiento y Asignación de Espectro (RSA, *Routing and Wavelength Assignment*). El problema RSA es una extensión del problema RWA para redes EON, donde el espectro asignado debe cumplir las restricciones físicas del medio y además introduce una nueva restricción, el de contigüidad del espectro. El RWA y el RSA son problemas NP-hard. Este trabajo propone, abordar el problema RSA como un Problema de Optimización Multi-Objetivo (MOP, *Multi-Objective Problem*), en este contexto se propone un modelo ILP Multi-Objetivo como una solución exacta, y un Algoritmo Genético Multi-Objetivo (MOGA) como un enfoque de aproximación que calculan la ruta y la asignación de espectro óptimas para un conjunto de solicitudes estáticas unicast con diferentes ancho de banda demandados. El MOILP y el MOGA buscan minizar la distancia total recorrida, el máximo FS utilizado y el costo total, simultáneamente. Pruebas realizadas muestran resultados promisorios para el MOGA respecto al MOILP. En redes pequeñas, las soluciones obtenidas por el MOILP fueron replicadas por el MOGA, mientras que para redes de tamaño mayor, el MOILP no logró conseguir resultados ya que no es un enfoque escalable. Por otro lado, se realizan comparaciones del MOGA y un GA propuesto en la literatura. Los resultados experimentales indican la competitividad del MOGA propuesto. Finalmente, se presenta un análisis del desempeño de las propuestas en diferentes números de rutas disponibles.

Contenidos

Dedicatoria	I
Agradecimientos	II
Abstract	III
Resumen	IV
Contenidos	V
Lista de Figuras	VIII
Lista de Tablas	XIII
Acrónimos	XIV
Lista de Símbolos	XVI
1. Introducción	1
1.1. Antecedentes	1
1.2. Objetivos	3
1.3. Organización del trabajo	4
I Marco Teórico	5
2. Redes Ópticas	7
2.1. Redes ópticas basadas en WDM	7
2.2. Redes Ópticas Elásticas	9
2.2.1. Definiciones de EON y Flexi-grid	10
2.3. Enrutamiento y Asignación de Espectro	11
2.3.1. Restricciones de RSA	12
2.3.2. Composición de RSA	13
2.4. Trabajos relacionados	14
3. Optimización Multi-Objetivo	20
3.1. Conceptos de Optimización Multi-Objetivo	20
3.1.1. Concepto Pareto	23
3.1.2. Método de la suma ponderada	24

3.2. Clasificación de problemas de optimización	27
3.3. Métodos para resolución de MOPs: Métodos exactos	28
3.4. Métodos para resolución de MOPs: Heurísticas	30
3.4.1. Algoritmos Evolutivos	30
3.4.2. Algoritmos Genéticos	32
3.4.3. Algoritmos Genéticos Multi-objetivos	35
II Trabajo propuesto	37
4. Programación Lineal Entera Multi-objetivo	39
4.1. Planteamiento del problema	39
4.2. Formulación MOILP	40
4.3. Ejemplo numérico	42
5. GA Multi-Objetivo	45
5.1. Implementación del MOGA	45
5.1.1. Representación	47
5.1.2. Población Inicial	47
5.1.3. Evaluación de Población	48
5.1.4. Selección de cromosomas para la siguiente generación	49
5.1.5. Cruzamiento	49
5.1.6. Mutación	50
5.1.7. Asignación de Espectro	50
5.1.8. Reemplazo	51
5.1.9. Criterio de Parada	51
III Pruebas experimentales y resultados	52
6. Pruebas experimentales y resultados	54
6.1. Ambiente de pruebas	54
6.2. Resultados de Carga Uniforme: MOILP vs MOGA	57
6.3. Resultados de Carga Aleatoria: MOILP vs MOGA	59
6.4. Resultados de Carga Uniforme: GA del estado del arte vs MOGA Propuesto	60
6.5. Resultados de Carga Aleatoria: GA del estado del arte vs MOGA Propuesto	61
6.6. Breve Resumen	61
7. Conclusiones	64
7.1. Conclusiones generales	64
7.2. Trabajos futuros	65
A. Carga Uniforme: MOILP vs. MOGA	66
A.1. Topología: 6 nodos	67
A.2. Topología: NSF-14	72
A.3. Topología: ARPA-2	77
B. Carga Aleatoria: MOILP vs. MOGA	82
B.1. Topología: 6 nodos	83

B.2. Topología: NSF-14	88
B.3. Topología: ARPA-2	93
C. Carga Uniforme: GA del estado del arte vs. MOGA propuesto	98
C.1. Topología: 6 nodos	99
C.2. Topología: NSF-14	103
C.3. Topología: ARPA-2	107
D. Carga Aleatoria: GA del estado del arte vs. MOGA propuesto	111
D.1. Topología: 6 nodos	112
D.2. Topología: NSF-14	116
D.3. Topología: ARPA-2	120
Referencias	124

Lista de figuras

2.1. Esquema de una red óptica WDM.	8
2.2. Esquema de una red óptica WDM.	8
2.3. Asignación de espectro en una rejilla fija vs. en una rejilla flexible.	11
2.4. Restricciones consideradas para calcular rutas y asignación de longitud de onda en redes ópticas.	13
2.5. Representación de contiguidad del espectro.	14
3.1. Método de la suma ponderada sobre el Frente Pareto en un MOP convexo. [Nar08]	26
3.2. Método de la suma ponderada sobre el Frente Pareto en un MOP no convexo. [Nar08]	27
3.3. Operador cruce de 2 puntos para un GA.	34
4.1. Topología de 5 nodos	43
4.2. Representación del enlace 0-1 atendiendo 2 solicitudes.	43
5.1. Representación del cromosoma utilizado.	47
5.2. Cruce de 2 reproductores.	50
6.1. Topología de red de 6 nodos.	55
6.2. Topología de red NSF de 14 nodos con distancia en kilómetros.	55
6.3. Topología de red Arpa-2 de 21 nodos.	55
A.1. Fitness obtenido por el MOILP para la topología de 6 nodos con carga uniforme.	67
A.2. Fitness promedio obtenido por el MOGA para la topología de 6 nodos con carga uniforme.	67
A.3. Máximo FS obtenido por el MOILP para la topología de 6 nodos con carga uniforme.	68
A.4. Máximo FS promedio obtenido por el MOGA para la topología de 6 nodos con carga uniforme.	68
A.5. Distancia total obtenida por el MOILP para la topología de 6 nodos con carga uniforme.	69
A.6. Distancia total promedio obtenida por el MOGA para la topología de 6 nodos con carga uniforme.	69
A.7. Costo total obtenido por el MOILP para la topología de 6 nodos con carga uniforme.	70
A.8. Costo total promedio obtenido por el MOGA para la topología de 6 nodos con carga uniforme.	70

A.9. Fitness obtenido por el MOILP para la topología NSF-14 con carga uniforme.	72
A.10. Fitness promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.	72
A.11. Máximo FS obtenido por el MOILP para la topología NSF-14 con carga uniforme.	73
A.12. Máximo FS promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.	73
A.13. Distancia total obtenida por el MOILP para la topología NSF-14 con carga uniforme.	74
A.14. Distancia total promedio obtenida por el MOGA para la topología NSF-14 con carga uniforme.	74
A.15. Costo total obtenido por el MOILP para la topología NSF-14 con carga uniforme.	75
A.16. Costo total promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.	75
A.17. Fitness obtenido por el MOILP para la topología ARPA-2 con carga uniforme.	77
A.18. Fitness promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.	77
A.19. Máximo FS obtenido por el MOILP para la topología ARPA-2 con carga uniforme.	78
A.20. Máximo FS promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.	78
A.21. Distancia total obtenida por el MOILP para la topología ARPA-2 con carga uniforme.	79
A.22. Distancia total promedio obtenida por el MOGA para la topología ARPA-2 con carga uniforme.	79
A.23. Costo total obtenido por el MOILP para la topología ARPA-2 con carga uniforme.	80
A.24. Costo total promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.	80
B.1. Fitness obtenido por el MOILP para la topología de 6 nodos con carga aleatoria.	83
B.2. Fitness promedio obtenido por el MOGA para la topología de 6 nodos con carga aleatoria.	83
B.3. Máximo FS obtenido por el MOILP para la topología de 6 nodos con carga aleatoria.	84
B.4. Máximo FS promedio obtenido por el MOGA para la topología de 6 nodos con carga aleatoria.	84
B.5. Distancia total obtenida por el MOILP para la topología de 6 nodos con carga aleatoria.	85
B.6. Distancia total promedio obtenida por el MOGA para la topología de 6 nodos con carga aleatoria.	85
B.7. Costo total obtenido por el MOILP para la topología de 6 nodos con carga aleatoria.	86
B.8. Costo total promedio obtenido por el MOGA para la topología de 6 nodos con carga aleatoria.	86

B.9. Fitness obtenido por el MOILP para la topología NSF-14 con carga aleatoria.	88
B.10. Fitness promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.	88
B.11. Máximo FS obtenido por el MOILP para la topología NSF-14 con carga aleatoria.	89
B.12. Máximo FS promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.	89
B.13. Distancia total obtenida por el MOILP para la topología NSF-14 con carga aleatoria.	90
B.14. Distancia total promedio obtenida por el MOGA para la topología NSF-14 con carga aleatoria.	90
B.15. Costo total obtenido por el MOILP para la topología NSF-14 con carga aleatoria.	91
B.16. Costo total promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.	91
B.17. Fitness obtenido por el MOILP para la topología ARPA-2 con carga aleatoria.	93
B.18. Fitness promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.	93
B.19. Máximo FS obtenido por el MOILP para la topología ARPA-2 con carga aleatoria.	94
B.20. Máximo FS promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.	94
B.21. Distancia total obtenida por el MOILP para la topología ARPA-2 con carga aleatoria.	95
B.22. Distancia total promedio obtenida por el MOGA para la topología ARPA-2 con carga aleatoria.	95
B.23. Costo total obtenido por el MOILP para la topología ARPA-2 con carga aleatoria.	96
B.24. Costo total promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.	96
C.1. Fitness promedio obtenido por el GA para la topología de 6 nodos con carga uniforme.	99
C.2. Fitness promedio obtenido por el MOGA para la topología de 6 nodos con carga uniforme.	99
C.3. Máximo FS promedio obtenido por el GA para la topología de 6 nodos con carga uniforme.	100
C.4. Máximo FS promedio obtenido por el MOGA para la topología de 6 nodos con carga uniforme.	100
C.5. Distancia total promedio obtenida por el GA para la topología de 6 nodos con carga uniforme.	101
C.6. Distancia total promedio obtenida por el MOGA para la topología de 6 nodos con carga uniforme.	101
C.7. Costo total promedio obtenido por el GA para la topología de 6 nodos con carga uniforme.	102
C.8. Costo total promedio obtenido por el MOGA para la topología de 6 nodos con carga uniforme.	102

C.9. Fitness promedio obtenido por el GA para la topología NSF-14 con carga uniforme.	103
C.10. Fitness promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.	103
C.11. Máximo FS promedio obtenido por el GA para la topología NSF-14 con carga uniforme.	104
C.12. Máximo FS promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.	104
C.13. Distancia total promedio obtenida por el GA para la topología NSF-14 con carga uniforme.	105
C.14. Distancia total promedio obtenida por el MOGA para la topología NSF-14 con carga uniforme.	105
C.15. Costo total promedio obtenido por el GA para la topología NSF-14 con carga uniforme.	106
C.16. Costo total promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.	106
C.17. Fitness promedio obtenido por el GA para la topología ARPA-2 con carga uniforme.	107
C.18. Fitness promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.	107
C.19. Máximo FS promedio obtenido por el GA para la topología ARPA-2 con carga uniforme.	108
C.20. Máximo FS promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.	108
C.21. Distancia total promedio obtenida por el GA para la topología ARPA-2 con carga uniforme.	109
C.22. Distancia total promedio obtenida por el MOGA para la topología ARPA-2 con carga uniforme.	109
C.23. Costo total promedio obtenido por el GA para la topología ARPA-2 con carga uniforme.	110
C.24. Costo total promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.	110
D.1. Fitness promedio obtenido por el GA para la topología de 6 nodos con carga aleatoria.	112
D.2. Fitness promedio obtenido por el MOGA para la topología de 6 nodos con carga aleatoria.	112
D.3. Máximo FS promedio obtenido por el GA para la topología de 6 nodos con carga aleatoria.	113
D.4. Máximo FS promedio obtenido por el MOGA para la topología de 6 nodos con carga aleatoria.	113
D.5. Distancia total promedio obtenida por el GA para la topología de 6 nodos con carga aleatoria.	114
D.6. Distancia total promedio obtenida por el MOGA para la topología de 6 nodos con carga aleatoria.	114
D.7. Costo total promedio obtenido por el GA para la topología de 6 nodos con carga aleatoria.	115
D.8. Costo total promedio obtenido por el MOGA para la topología de 6 nodos con carga aleatoria.	115

D.9. Fitness promedio obtenido por el GA para la topología NSF-14 con carga aleatoria.	116
D.10. Fitness promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.	116
D.11. Máximo FS promedio obtenido por el GA para la topología NSF-14 con carga aleatoria.	117
D.12. Máximo FS promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.	117
D.13. Distancia total promedio obtenida por el GA para la topología NSF-14 con carga aleatoria.	118
D.14. Distancia total promedio obtenida por el MOGA para la topología NSF-14 con carga aleatoria.	118
D.15. Costo total promedio obtenido por el GA para la topología NSF-14 con carga aleatoria.	119
D.16. Costo total promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.	119
D.17. Fitness promedio obtenido por el GA para la topología ARPA-2 con carga aleatoria.	120
D.18. Fitness promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.	120
D.19. Máximo FS promedio obtenido por el GA para la topología ARPA-2 con carga aleatoria.	121
D.20. Máximo FS promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.	121
D.21. Distancia total promedio obtenida por el GA para la topología ARPA-2 con carga aleatoria.	122
D.22. Distancia total promedio obtenida por el MOGA para la topología ARPA-2 con carga aleatoria.	122
D.23. Costo total promedio obtenido por el GA para la topología ARPA-2 con carga aleatoria.	123
D.24. Costo total promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.	123

Lista de tablas

2.1. Resumen de principales aportes para la resolución de RSA	19
4.1. Tabla de ruteo para la topología de 5 nodos con $K = 2$	43
5.1. Tabla de ruteo para la topología de 5 nodos con $K = 3$	47
6.1. Parámetros utilizados para la ejecución del MOGA.	57
6.2. Escenarios de ejecuciones.	58
6.3. Parámetros utilizados para la ejecución del GA.	61
6.4. Mejoras obtenidas (%), MOILP vs. MOGA, MOGA vs. GA.	63
A.1. Máximo FS promedio obtenido por el MOGA para la topología 6 nodos con carga uniforme.	71
A.2. Máximo FS promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.	76
A.3. Máximo FS promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.	81
B.1. Máximo FS promedio obtenido por el MOGA para la topología 6 nodos con carga aleatoria.	87
B.2. Máximo FS promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.	92
B.3. Máximo FS promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.	97

Acrónimos

ACO	Ant Colony Optimization
AFA-CA	Adaptive Frequency Assignment with Collision Avoidance
BCO	Bee Colony Optimization
BF	Best First
BLP	Binary Linear Programming
BLSA	Balanced Load Spectrum Allocation
CAPEX	Capital Expenditure
CF	Central Frequency
DE	Differential Evolution
DWDM	Dense Wavelength Division Multiplexing
EA	Evolutionary Algorithm
EE	Eficiencia Espectral
EON	Elastic Optical Networks
EOP	Elastic Optical Path
FS	Frequency Slots
GA	Genetic Algorithm
Gbps	Giga Bits Per Second
GHz	Giga Herz
GRASP	Greedy Randomized Adaptive Search Procedure
ILP	Integer Linear Programming
IP	Internet Protocol
LP	Linear Programming
MO	Multi Objective
MOGA	Genetic Algorithm Multi Objective
MOILP	Multi Objective Integer Lineal Programming

MOP	Multi-objective Problem
MPGA	Multi Population Genetic Algorithm
MPLS	Multi-Protocol Label Switching
NLP	No Linear Programming
OFDM	Orthogonal Frequency Division Modulation
OTN	Optical Transport Network
PF	Pareto Front
PO	Path Oriented
QoS	Quality of Service
RMLSA	Routing Modulation Level Spectrum Allocation
ROADM	Reconfigurable Optical Add Drop Multiplexing
RSA	Routing and Spectrum Allocation
RWA	Routing and Wavelength Allocation
SOP	Single Objective Problem
WDM	Wavelength Division Multiplexing

Lista de Símbolos

E	Conjunto de enlaces en G . 40
F	Función objetivo. 24
F_{total}	Cantidad de FS que posee la fibra. 40
G	Grafo de red. 40
GB	Cantidad de FS para Banda Guarda. 40
K	Cantidad de rutas disponibles. 18 , 40
P	Conjunto de rutas. 40
P_c	Conjunto Pareto. 24
P_f	Frente Pareto. 24
SD	Cantidad de demandas. 40
V	Conjunto de vértices en G . 40
X	Espacio decisión. 21
Y	Espacio objetivo. 21
Λ_{sd}	Primer FS asignado a la solicitud sd . 41
α_{sd}	Cantidad de FS solicitados por la solicitud sd . 40
$\delta_{sd,s'd'}$	Indicador de diferencias de FS. 41
a	Vector decisión. 23
b	Vector decisión. 23
c	Carga de tráfico. 62
$costoMaximo$	Costo total de las solicitudes considerando sus distancias máximas. 40
d	Nodo destino. 40
$dist_p^{sd}$	Distancia de la ruta p . 40
$distanciaMaxima$	Distancia máxima recorrida considerando las rutas más largas. 40
$e(x)$	Conjunto de restricciones. 21

<i>espectroMaximo</i>	Índice del máximo FS disponible. 40
$f(x)$	Vector objetivo. 21
h	Peso de la función objetivo. 25
l	Cantidad de funciones objetivo. 21
mn	Índice de enlace direccional. 41
n	Cantidad de parámetros. 21
p	Ruta. 41
r	Cantidad de restricciones. 21
s	Nodo fuente. 40
sd	Solicitud. 41
t	Topología. 62
u	Vector de coeficiente tecnológico. 30
v	Vector de requerimientos. 30
w	Vector de coeficientes de costo. 29
x	Vector decisión. 21
y	Vector objetivo. 21
z	Función objetivo. 29

Capítulo 1

Introducción

1.1. Antecedentes

La creciente demanda en el tráfico de red, ha impulsado al estudio e investigación de mejoras en la transmisión de datos en las redes actuales. Las redes más expandidas y utilizadas en la actualidad son las redes basadas en Multiplexación por División de Longitud de Onda (WDM, *Wavelength Division Multiplexing*) [Pat+11a]. A pesar de las altas tasas de transmisión de las redes WDM, este tipo de red converge al problema de la ineficiente utilización del espectro disponible a causa de la granularidad rígida que ofrecen.

El tráfico de datos que soportan las redes de telecomunicaciones, es cada vez más heterogéneo e impredecible debido al desarrollo de nuevos servicios para el usuario, tales como el video bajo demanda o la telefonía IP (*Internet Protocol*), entre otros. Este hecho, junto con el aumento continuo de demanda de tráfico en la red, motiva una creciente preocupación por disponer de una red dinámica y flexible, capaz de adaptarse a los cambios en el flujo de datos y que además ofrezca un rendimiento alto de los medios disponibles.

La mayor parte de las redes actuales utilizan conmutación de circuitos mediante WDM ofreciendo altas velocidades de transmisión [Pat+11a]. Sin embargo, la naturaleza de WDM y esta arquitectura, introducen una alta rigidez en la red, causando un bajo rendimiento del ancho de banda disponible y poca flexibilidad a la hora de re-configurarse en función de las variaciones del tráfico.

Un nuevo concepto en las tecnologías de transporte para redes ópticas son las Redes Ópticas Elásticas (EON, *Elastic Optical Networks*) [Jin+09]. Se puede definir a las EON como redes donde se emplea una rejilla de espectro flexible (*flexi-grid*), con ancho espectral variable por canal según la demanda de ancho de banda, permitiendo una separación espectral flexible entre canales con el propósito de optimizar la eficiencia en el uso del espectro.

La introducción de canales con ancho de banda variable introduce una complejidad adicional a la hora del proceso de enrutamiento: la asignación del espectro. Se conoce como Enrutamiento y Asignación de Espectro (RSA, *Routing and Spectrum Allocation*) al problema de encontrar la ruta apropiada para un par de nodos fuente-destino y asignar Ranuras de Frecuencia (FS, *Frequency Slots*) adecuadas a la solicitud recibida [Ger+12].

Con este planteamiento del problema RSA, la mayor dificultad que se presenta, son las restricciones que plantea el problema. Esto introduce una mayor complejidad de cómputo a la hora de calcular el camino óptimo para cada petición optimizando a su vez la asignación de espectro, lo que al final se traduce en tiempos de computación demasiado grandes.

El cálculo de la solución óptima a este problema, en general en la literatura se presenta como un problema NP-hard [WCP11]. RSA ha sido abordado mediante métodos exactos tales como el de Programación Lineal Entera (ILP, *Integer Linear Programming*) y algoritmos heurísticos tales como Algoritmos Genéticos (GA, *Genetic Algorithm*) [CTV11] [KWJ11] [GM17] y Optimización con Colonia de Abejas (BCO, *Bee Colony Optimization*) [Mar17].

En los distintos trabajos investigados se proponen varias heurísticas y planteamientos con métodos exactos para abordar el problema RSA, donde en la mayoría de los casos se propone maximizar o minimizar una única función objetivo: asignar rutas óptimas o asignar el espectro lo más eficientemente posible [Kli13] [Tak+10] [Pat+11a].

En este trabajo se propone atacar al RSA extendiendo los trabajos de la literatura planteando múltiples objetivos a minimizar, se emplea un modelo ILP y un GA, basados en suma ponderada, para la búsqueda de soluciones óptimas, con demandas de tráfico estáticas y con carga de tráfico uniforme y aleatoria, dada una lista precalculada de rutas disponibles.

Las principales contribuciones esperadas de este trabajo son:

- abordar el problema RSA en un contexto de optimización multiobjetivo basado en suma ponderada,
- el desarrollo de un modelo exacto basado en ILP,
- el desarrollo de una heurística, que sea escalable para problemas de gran porte, y
- una comparación de resultados entre las propuestas y un algoritmo RSA representativo de la literatura.

1.2. Objetivos

General

- Diseñar e implementar un modelo exacto y una meta-heurística, basados en Optimización Multi-Objetivo de suma ponderada, que permitan resolver el problema RSA dada una lista de demandas offline punto-a-punto.

Específicos

- **Objetivo 1:** Analizar y reportar las principales contribuciones que abordan el problema RSA.
- **Objetivo 2:** Diseñar e implementar un modelo exacto que obtenga el resultado óptimo en redes de baja complejidad.
- **Objetivo 3:** Diseñar e implementar una meta-heurística que obtenga resultados promisorios en redes de mayor complejidad en un tiempo computacional aceptable.
- **Objetivo 4:** Comparar la meta-heurística propuesta con una publicada en la literatura.

1.3. Organización del trabajo

El resto del trabajo, está organizado de la siguiente forma:

La parte 1 está estructurada de la siguiente forma: Capítulo 1 presenta los trabajos relacionados y las principales motivaciones que llevaron a cabo esta investigación. En los capítulos 2 y 3 se presentan conceptos sobre Redes Ópticas y Optimización Multi-objetivo.

Luego en la parte 2 se detallan las implementaciones propuestas por este trabajo. En el capítulo 4 se presenta el modelo ILP mientras que en el capítulo 5 se presenta el Algoritmo Genético propuesto.

En la parte 3 se presentan los resultados experimentales, conclusiones y trabajos futuros en los capítulos 6 y 7 respectivamente.

Finalmente se presetan los apéndices y las referencias bibliográficas.

Parte I

Marco Teórico

Capítulo 2

Redes Ópticas

Muchos trabajos de investigación han sido propuestos en la literatura para atacar el problema RSA en EON [Ger+12]. En las secciones siguientes se detallan conceptos sobre redes WDM, EON y sobre el problema RSA.

2.1. Redes ópticas basadas en WDM

Las redes basadas en tecnología WDM se han convertido rápidamente en una de las principales tecnologías en las redes de comunicación debido a su mecanismo de transmisión altamente fiable, de coste efectivo y capaz de hacer frente a los crecientes requerimientos de ancho de banda [RBPR14]. Éstas son algunas de las razones por las cuales un gran esfuerzo es destinado a la investigación de redes ópticas que abarcan desde estudios de los medios de transmisión hasta el establecimiento de niveles de calidad de servicio (QoS, *Quality of Services*) para clientes que desean transmitir información [Som06], [NBPR07], [Tan03], [GNS00], [Hil+12], [Muk06], [HHM12], [GS02], [Puj12].

La tecnología WDM permite explotar la capacidad de la fibra óptica, mediante la división del ancho de banda total de la fibra en varios canales no solapados (longitudes de onda), permitiendo la transmisión independiente de datos por cada uno de los canales obtenidos. De esta manera se logra velocidades del orden de los 40 Gbps (*Giga Bits Per Second*) por canal [Som06], [SN99], [Ehr06].

Un esquema del funcionamiento de una red óptica utilizando la tecnología WDM se describe a continuación: cada señal transmitida utiliza una longitud de onda, las cuales son

multiplexadas a través de un multiplexador de longitud de onda para ser transmitidas a través de la red. Generalmente se utilizan amplificadores de potencia en los enlaces para mantener la calidad de la señal. Luego son añadidas o removidas señales mediante el Add Drop Multiplexer Reconfigurable (ROADM, *Reconfigurable Optical Add Drop Multiplexer*) llegando finalmente la señal resultante al demultiplexador en el nodo receptor, que se encarga de separar las longitudes de onda. Dicho procedimiento puede ser observado en la Figura 2.1.




FIGURA 2.1: Esquema de una red óptica WDM.

Los componentes básicos en un nodo se observan en la Figura 2.2, en el cual, se reciben las señales ópticas provenientes de las fibras y luego los demultiplexadores se encargan de demultiplexar, es decir, separar las longitudes de onda. Al tener separadas las longitudes de onda, las matrices de conmutación se encargan de redirigir dichas longitudes de onda al puerto de salida pre-establecido para cada una de ellas. Por último el multiplexador de longitud de onda, reúne las longitudes de onda y encamina la señal óptica por el siguiente enlace.




FIGURA 2.2: Esquema de una red óptica WDM.

En el diseño de una red WDM se busca definir las características físicas de los enlaces y nodos ópticos, típicamente minimizando el costo de diseño bajo restricciones de niveles de bloqueo. El problema de diseño es complejo pudiendo distinguirse en él varios sub-problemas como podrían ser: el dimensionamiento del número de fibras ópticas en los enlaces, y del número de longitudes de onda en multiplexores, la ubicación de

amplificadores ópticos, la ubicación de conversores de longitudes de onda, entre otros [Som06].

Esta tecnología se basa en la transmisión de canales ópticos sobre una misma fibra de igual ancho de banda, sobre una rejilla espectral fija establecida por la ITU-T [RBPR14]. Este enfoque, en el cual los canales de transmisión poseen un ancho de banda fijo, restringe la capacidad de la red de adaptarse a las necesidades reales de transmisión y la posibilidad de seguir creciendo en capacidad en la transmisión de largas distancias, es por ello que surge la necesidad de un nuevo paradigma en redes: las redes flexibles, que serán descritas a continuación.

2.2. Redes Ópticas Elásticas

Un nuevo paradigma investigado para las redes ópticas son las Redes Ópticas Elásticas (EON, *Elastic Optical Network*) [OG12]. El interés por las redes elásticas viene motivado principalmente por el continuo aumento del tráfico en la red y la necesidad de los operadores de aumentar la capacidad y el rendimiento de los tramos centrales de sus redes de transporte. La demanda de tráfico continúa creciendo. La transmisión óptica a 10 Gbps está ampliamente desplegada y algunos Proveedores de Servicio (SP, *Service Providers*) ya están comenzando a instalar tecnologías con tasa de datos a 40 Gbps e incluso a 100 Gbps en una misma longitud de onda.

En la actualidad la tecnología de Redes de Transporte Óptico (*OTN, Optical Transport Network*) utilizada en redes ópticas es la WDM. Esta tecnología es capaz de transportar múltiples canales, entre 40-80 [Win09], en Multiplexación por Longitud de Onda Densa (DWDM, *Dense Wavelength Division Multiplexing*) en una misma fibra basándose en portadoras de distintas longitudes de onda.

Esta tecnología también introduce una granularidad fija en el ancho de banda de los canales transportados a través de la fibra, limitada por la distancia entre las distintas portadoras a una longitud fija. La Recomendación ITU-T G.694.1, establece una serie de rejillas espectrales fijas, que dividen el espectro óptico relevante entre 1530–1565 nm (banda C), para el uso de DWDM, que van desde los 12.5 GHz. (*Giga Herz*) hasta los 100 GHz, aunque las más utilizadas y extendidas son la de 50 GHz y 100 GHz [Rec12].

Este hecho implica, por un lado que canales con una demanda más baja que la máxima soportada por la granularidad impuesta, infrautilicen recursos de la red. Y por otra parte, en la actualidad, ya se está investigando la transmisión de canales a 400 Gbps e incluso 1 Tbps, velocidades o tasas de datos que no pueden ser transmitidas a largas distancias mediante una única portadora dentro de la rejilla de 50 GHz.

Estos dos factores, la infrautilización de recursos en demandas pequeñas y la limitación en la máxima velocidad impuesta por la rejilla fija, deben ser tomados en cuenta conjuntamente, ya que en la actualidad y en el futuro, el tráfico en la red es y será altamente heterogéneo por lo que la flexibilización en la disposición de los recursos de la red óptica es un reto ante el que la industria se enfrentará en los próximos años.

Formatos de modulación multiportadora como Multiplexación por División de Frecuencias Ortogonales (OFDM, *Orthogonal Frequency Division Modulation*), están atrayendo la atención de numerosos investigadores para abordar este problema [CTV11] [Zhe+10] [Zha+13]. Estas técnicas multiportadora permiten la transmisión de canales de gran capacidad mediante la división en subportadoras de menor velocidad multiplexadas conjuntamente a través de la red. OFDM permite ajustar la velocidad de transmisión, a las necesidades del cliente, mediante la elección del número de subportadoras a transmitir.

Por consiguiente, la solución a estos problemas consistirá en flexibilizar la rejilla espectral, permitiendo la transmisión de canales con anchos de banda variable que se ajusten a la demanda de dichos canales.

2.2.1. Definiciones de EON y Flexi-grid

Se puede empezar definiendo una EON como una OTN donde el equipamiento puede manejar canales ópticos de ancho de banda variable, y cuyos elementos de conmutación Conexión Óptica Cruzada (OXC, *Optical Cross Connects*) ó Multiplexores Add-Drop Reconfigurables (ROADM, *Reconfigurable Optical Add Drop Multiplexing*) [Enn+06] pueden soportar distintas granularidades en la anchura espectral de los canales que transportan la información.

El primer cambio importante en la arquitectura de las EON es la sustitución de la rejilla fija (Fixed grid) por una nueva flexible (Flexi-grid). La ITU-T está trabajando en una revisión del estándar G.694.1 [Rec12], en una división del espectro óptico flexible

llamada Flexi-grid. El espectro óptico de la banda C (1530–1565 nm) es dividido en FS de un tamaño fijo (6.25, 12.5, 25, 50 GHz.) [Zha+11], y se asigna una Frecuencia Central (CF, *Central Frequency*) a cada Camino Óptico Elástico (EOP, *Elastic Optical Path*) que debe coincidir con el principio o el final de estas ranuras. En la Figura 2.3 se presenta un esquema de una rejilla fija y de una rejilla flexible. Para la rejilla fija, se puede observar el ineficiente uso del espectro debido a la división fija que posee el espectro, de 50 GHz. entre CFs; mientras que en la rejilla flexible se puede observar el espectro libre obtenido gracias a la fina granularidad que ofrece y que permite asignar de manera flexible solo el ancho de banda requerido.

En segundo lugar hay que tener en cuenta los elementos de la red que pueden hacer posible el despliegue de este tipo de redes. Ya se ha hablado de la necesidad de que los transpondedores (transmisores ópticos) sean capaces de transmitir señales de diferente tasa de datos. En la Figura 2.2 se pueden observar dichos elementos de conmutación, explicada con detalle en la siguiente sección.

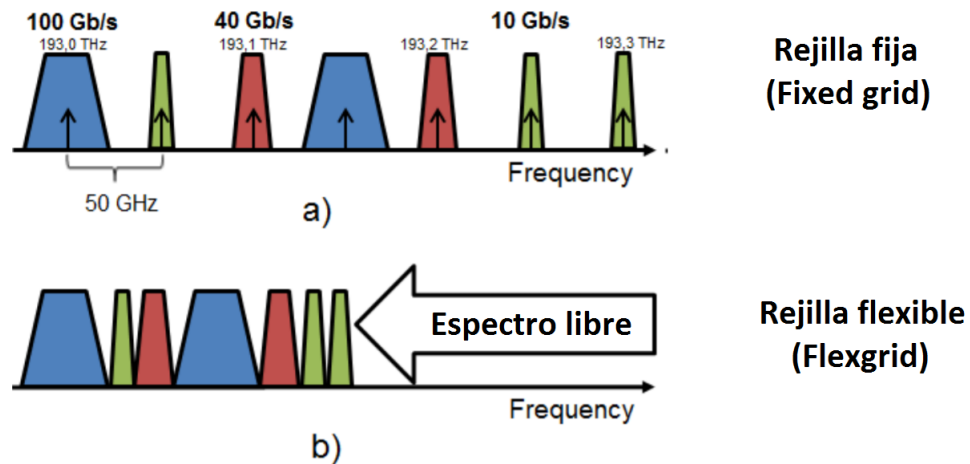


FIGURA 2.3: Asignación de espectro en una rejilla fija vs. en una rejilla flexible.

2.3. Enrutamiento y Asignación de Espectro

Las EON mejoran ampliamente la tasa de transmisión de datos ya que divide el espectro en porciones de frecuencias llamadas FS permitiendo utilizar con más eficiencia las bandas definidas por la ITU-T. El tamaño actual propuesto por la ITU-T varía entre

25 GHz., 12.5 GHz. y 6.25 GHz., siendo los dos últimos los más utilizados, teniendo en cuenta que estos valores de granularidad podrían variar de acuerdo a lo desarrollado por la industria.

El problema de establecer caminos para cada petición seleccionando una ruta apropiada y asignando el ancho de banda requerido se conoce como el problema RSA [Ger+12]. El problema RSA en EON es análogo al problema de Enrutamiento y Asignación de Longitud de Onda (RWA, *Routing and Wavelength Allocation*) en redes basadas WDM. La diferencia entre RSA y RWA es la capacidad de asignar de manera flexible el espectro de frecuencias [LG12]. El RSA es considerado un problema NP-completo [WCP11] y se puede clasificar en dos tipos: Offline o Estático y Online o Dinámico [Cas+12]. En un problema RSA offline, ya se tiene como un dato de entrada la lista de todas las solicitudes de transmisión, realizándose el análisis y la resolución con ese dato de entrada. Sin embargo, en un escenario del problema RSA online, el análisis y la resolución se van realizando conforme van llegando las solicitudes dinámicamente.

Las redes ópticas WDM, presentan dos restricciones, las restricciones de Continuidad y de No Superposición. Además de dichas restricciones, que son propias de las redes ópticas WDM, se presenta una nueva restricción en las redes elásticas, llamada Restricción de Contigüidad. En la siguiente sección se describen las restricciones mencionadas.

2.3.1. Restricciones de RSA

Como se mencionó, las redes ópticas WDM poseen dos restricciones propias de capa física (continuidad y no superposición). Al agregar la capacidad de elasticidad para las redes ópticas mediante la división del espectro en FS, se agrega una nueva restricción: la restricción de contigüidad. Dicha restricción requiere que los FS utilizados por una solicitud estén de manera consecutiva, es decir, que no existan FS intermedios pertenecientes a otra solicitud ni FS correspondientes a banda guarda.

A continuación, se definen formalmente las 3 restricciones [Ger+12], [Ler+13]:

- La continuidad del espectro: define que los recursos espectrales asignados (FS) deben de ser los mismos en toda la ruta que corresponde a un EOP dado que no se dispone de capacidad de conversión de longitud de onda.

- La restricción de no superposición: define que el espectro asignado a una solicitud de tráfico no debe de interferir o solaparse con otra solicitud de tráfico.
- La contigüidad del espectro: esta restricción define que de todos los FS pertenecientes a una solicitud, cada uno debe ser adyacente al otro en un mismo canal.

En las redes ópticas, la elección de la longitud de onda está condicionada a que sea la misma en todos los enlaces de la ruta, para que, de esta manera, no sea necesaria la conversión electro-óptica de la señal en ningún salto de la ruta. Esta es, la restricción de Continuidad, mostrada en la Figura 2.4 donde la *Solicitud 1* utiliza la misma longitud de onda en todos los enlaces que utiliza su ruta. La segunda restricción, la de No Superposición, también se observa en la Figura 2.4, donde la *Solicitud 1* y la *Solicitud 2* utilizan distintas longitudes de onda para transmitir datos.

En la Figura 2.5 se puede ver un ejemplo de 2 solicitudes, *Solicitud 1* y *Solicitud 2*, cuyas rutas tienen un enlace en común, el enlace *A-B*. Ambas solicitudes demandan 2 FS. Se puede observar que los FS 1 y 2 fueron asignados a la *Solicitud 1* y quedan 2 FS libres pero no contiguos. Al llegar la *Solicitud 2*, no puede ser atendida ya que no existen 2 FS libres y que además sean contiguos.




FIGURA 2.4: Restricciones consideradas para calcular rutas y asignación de longitud de onda en redes ópticas.

2.3.2. Composición de RSA

El planteamiento básico del problema RSA se basa en una demanda dada, compuesta por un par de nodos origen-destino y una cantidad de FS solicitada, se debe encontrar una ruta que tenga disponible la cantidad de FS que la demanda solicita y que cumpla las restricciones mencionadas [LG12] [Ger+12].

Para satisfacer una demanda, se divide el proceso en: enrutamiento y selección de recursos espectrales, en la primera se realizan los cálculos de la ruta entre el nodo fuente




FIGURA 2.5: Representación de contigüidad del espectro.

y el nodo destino a través de una topología de red dada; mientras que en la segunda se eligen las ranuras de frecuencia a ser asignados a la demanda definidas por una CF y un ancho de banda (anchura de la ranura). En las redes WDM, se realiza el RWA, buscando un camino físico a través de la red y asignando una longitud de onda para transportar ese canal. La selección de esta longitud de onda se condiciona para que sea la misma durante todo el trayecto físico, de modo que de esta manera no es necesario utilizar convertidores de longitud de onda en ningún salto (restricción de continuidad) y también que corresponda a una única solicitud (restricción de no superposición). Las redes elásticas también están limitadas por ambas restricciones ya que son restricciones propias de las redes elásticas.

Entonces, durante todo el trayecto se utilizan los mismos FS y cada FS es utilizado por una única solicitud, esto es para cumplir con dichas restricciones, pero además, como ya se mencionó anteriormente, las redes elásticas presentan una nueva restricción, la restricción de contigüidad en el espectro, la cual condiciona a mantener adyacentes a todas las ranuras de frecuencia que atienden a una demanda.

La asignación de espectro puede ser hecha implementando cualquier heurística, como [DAR16]: First fit, Random, Menor fragmentación de espectro, entre otros.

2.4. Trabajos relacionados

Como el RSA es considerado un problema NP-completo [WCP11], ha sido tratado con varias técnicas, exactas y heurísticas, tanto para tráfico estático como para tráfico dinámico. Entre las técnicas exactas se encuentra el ILP, mientras que entre las heurísticas se encuentran las Optimizaciones con Colonia de Abejas (BCO, *Bee Colony Optimization*)

[Mar17], los Algoritmos Genéticos (GA, *Genetic Algorithm*) [Kli13] [WMM14] [CR13] [HH17], entre otros [Wan+13] [GKW14].

Diferentes modelos ILP para instancias pequeñas, y distintas heurísticas para escenarios de tamaño más real, han sido utilizados exitosamente para resolver el problema RSA. Por ejemplo, en [CTV10], un modelo ILP para minimizar el uso del espectro es presentado para servir a una matriz de tráfico en un EON. Los autores proponen un método que divide el problema en dos subproblemas, el primero es el ruteo y el segundo es la asignación de espectro, y los resuelve secuencialmente, utilizando un enfoque basado en rutas. Ellos también proponen un algoritmo heurístico que sirve las conexiones una a una en forma secuencial. Luego, en [CTV11], los autores amplían sus resultados previos incluyendo la consideración del nivel de modulación en la formulación ILP. Con esta nueva consideración, se definió un nuevo problema llamado Enrutamiento, Nivel de Modulación y Asignación de Espectro (RMLSA, *Routing Modulation Level Spectrum Allocation*), quedando fuera del alcance de este trabajo. Tampoco se consideran otros problemas como *Fragmentation Aware* y *Tráfico Dinámico*. Otra formulación ILP y la prueba de que el problema RSA es un problema NP-completo se puede encontrar en [WCP11]. En este trabajo, junto con la formulación ILP, se introdujeron dos heurísticas, la más corta con reutilización máxima del espectro y la asignación equilibrada de la carga del espectro, ambos con un enfoque basado en rutas.

Una formulación ILP diferente con variables y restricciones que dependen de los recursos de frecuencias se presentó en [KW11]. Al igual que los otros enfoques, los autores proponen una heurística para hacer frente a los escenarios realistas, llamado Asignación de Frecuencia Adaptativo Evitando Colisión (AFA-CA, *Adaptive Frequency Assignment Collision Avoidance*) [WK13a] [KW12] [WGK13]. En [Vel+12], los autores proponen un modelo ILP que utiliza el concepto de canales para la representación de los recursos espectrales contiguos. Con esta consideración, mostraron que su modelo ILP funciona mejor que los modelos previos de ILP e incluso puede aplicarse a instancias más realistas.

Debido a la complejidad del RSA, aparte de la formulación ILP y la heurística, se han propuesto algunos algoritmos metaheurísticos y novedosos para proporcionar soluciones originales al problema [KC11] [Alm+13] [WK13a] [MZ12]. Por ejemplo, en [Gon+12], los autores propusieron un GA de dos poblaciones (*MPGA*, *Multi Population Genetic Algorithm*) que puede resolver el problema RMLSA para las redes a gran escala. Utilizaron

dos poblaciones de individuos evolucionando en paralelo para aumentar la robustez de su algoritmo. Más adelante en [Wan+13] y [Wan+12b], se propusieron algunos algoritmos dinámicos RSA empleando la Optimización de Colonia de Hormigas (*ACO, Ant Colony Optimization*). Los autores compararon el rendimiento de su enfoque basado en ACO con otros algoritmos RSA en términos de probabilidad de bloqueo. Más recientemente, en [GKW14], un algoritmo basado en búsqueda Tabú se propuso para resolver el problema RSA en tres topologías de red realistas. Los autores comparan sus resultados con algunas heurísticas de la literatura mostrando que el método de búsqueda tabú puede obtener buenos resultados y superar a otros algoritmos en términos de uso del espectro.

Una de las publicaciones más recientes en la literatura, propone un algoritmo basado en BCO [Mar17], en el cual se busca minimizar el índice máximo de FS utilizado. Dicho trabajo compara sus resultados con resultados proveídos por implementaciones existentes en la literatura sobre optimización con Evolución Diferencial (DE, *Differential Evolution*) [Lez+16], y obtiene mejoras significativas en cuanto a tiempos de CPU y velocidad de convergencia.

Una revisión extensa y la clasificación de los diferentes enfoques RSA, incluyendo sus pros y contras se puede encontrar en [Ger+12].

En [Ped+12] se presenta un análisis del costo de Gastos de Capital (CAPEX, *Capital Expenditure*) que implica un conjunto de FS requerido para implementar una red del tipo Multicapa (MPLS, *Multi Protocol Label Switching*), mediante la heurística GRASP (*Greedy Randomized Adaptive Search Procedure*). Esta heurística divide el proceso en dos fases, la primera se basa en búsqueda aleatoria para orden y ruteo, y la segunda fase utiliza la técnica FF para asignación de espectro.

En [ZDLM12] son expuestas las diferencias entre un ILP para RWA y para RSA, y un análisis de complejidad de algoritmo es realizado. En el mismo trabajo, dos algoritmos heurísticos para RSA son expuestos. Estos tienen un rendimiento mejor que el ILP en redes de mayores dimensiones. Uno de los algoritmos prioriza minimizar el uso espectral, juntando todos los caminos ópticos originados en una fuente en común y que poseen una ruta en común. El otro algoritmo prioriza minimizar el número de transmisores utilizados, modificando partes del primer algoritmo para utilizar la capacidad máxima

espectral de un canal en lugar de la capacidad real de este. Con estos algoritmos heurísticos, el tiempo computacional fue reducido, lo que es considerado una mejora comparado con el ILP con el cual se diferencia en horas de cómputo.

El trabajo presentado en [LK15] propone un modelo ILP con un enfoque basado en enlaces con el objetivo de minimizar la utilización del espectro considerando la restricción de calidad del servicio. Otro trabajo, el presentado en [Tri+16], propone ambos enfoques, el basado en rutas y un enfoque basado en enlaces, este último llamado Asignación de Espectro con Carga Balanceada (*BLSA, Balanced Load Spectrum Allocation*) determina la ruta balanceando la carga dentro de la red para minimizar el número máximo de FS utilizados en la fibra.

En cuanto a funciones objetivo a minimizar, gran parte de la literatura propone minimizar un único objetivo, entre los que se encuentran: minimizar el máximo FS utilizado [AW14] [Wan+12a] [HH17], minimizar la cantidad total de FS utilizados [KC11] [GKW14] [WK13a] [Cai+13] [KW12] [Kli+16], costos [Ped+12] [CTV10], distancia promedio [Lez+16] [Mar17] y entropía [WPL15].

También se presentan enfoques multi-objetivos. Por ejemplo, en [Hai17], se minimizan el máximo FS utilizado y la cantidad total de FS utilizados. El trabajo [Mar17], está basado en un modelo previo propuesto en [Hai17], ambos proponen minimizar el máximo FS utilizado y la distancia promedio, pero no poseen verificación de restricciones, por lo que los resultados podrían incluir soluciones no factibles.

Como se observa existen varias propuestas de algoritmos heurísticos para tratar el RSA, algunos proponen minimizar el espectro utilizado, mientras otros minimizan el costo del ruteo o niveles de modulación. Estos trabajos proponen distintas formulaciones para representar la heurística, y algunos se basan en un previo modelo ILP.

Un resumen de los trabajos analizados se presenta en la Tabla 2.1. La tabla nos muestra la siguiente información:

- Tipo de optimización: desde el punto de vista de cantidad de objetivos, Multi-Objetivo (MOP, *Multi Objective Optimization Problem*) o Mono-Objetivo (SOP, *Single Objective Optimization Problem*). Dichos conceptos son explicados más adelante en la sección 3.2.

- Permutación de solicitudes: en técnicas basadas en RSA simple, el orden de las solicitudes altera la solución final. Se observan técnicas como FF (*First Fit*), que va atendiendo las demandas de acuerdo al orden en el cual fueron recibidas, RF (*Random Fit*) que elige aleatoriamente la demanda que atenderá y BF (*Best First*) el cual selecciona el orden de solicitud en función a una medida de calidad. Se observan también estrategias elaboradas con heurísticas y metaheurísticas.
- Ruteo: se observan diferentes esquemas de enrutamiento, como FF, heurísticas o metaheurísticas, como también basados en selección de Orientado a Camino (PO, *Path Oriented*).
- Asignación de espectro: algoritmo con el cual es realizada la asignación de espectro, se observan FF, FR, AFA (*Adaptative Frequency Assignment*), heurísticas y metaheurísticas.
- Función Objetivo: objetivo a optimizar, tales como costo, espectro y distancia.

En dicha tabla, se pueden apreciar varios trabajos en los cuales un mismo algoritmo fue utilizado para más de un subproblema. Por ejemplo, en el ítem 7, podemos observar que la heurística propuesta, GRASP, fue utilizada tanto para permutación de solicitudes como para ruteo, lo que indica que aborda ambos problemas simultáneamente en un enfoque de optimización conjunta.

En este trabajo, se propone optimizar varios recursos simultáneamente, por lo que se presenta una implementación multi-objetivo tanto para el ILP como para el GA. Se utiliza un enfoque basado en rutas, donde se cuenta con una lista precalculada de K rutas disponibles para satisfacer las peticiones (K-shortest path) [WMM14]; y se atienden todas las peticiones al mismo tiempo. Además, se realiza un análisis del impacto que provoca la cantidad de rutas disponibles (K) para encontrar las soluciones óptimas.

TABLA 2.1: Resumen de principales aportes para la resolución de RSA

	Referencia	Secuencia de solicitudes	Routing	Rutas pre-calculadas	Asignación de FS	Tipo de optimización	Función Objetivo
1	[CTV10]	Heurística	Heurística	Path Oriented	FF	SOP	Costo
2	[KW11]		Heurística	Path Oriented	FF	SOP	FS usados
3	[KC11]		Heurística	Path Oriented	FF	SOP	FS usados
4	[WCP11]	Ordenamiento decreciente por demanda	Shortest Path	Link Oriented	Reuso de Espectro Máximo basado en FF	SOP	Índice máx. de FS
5	[KW12]	FF	Heurística	Path Oriented	AFA	SOP	FS usados
6	[Ped+12]	GRASP	Heurística	Path Oriented	FA-FF	SOP	CAPEX
7	[Wan+12a]			Path Oriented	FF	SOP	Índice máx. de FS
8	[Cai+13]			Link Oriented	SW	SOP	FS usados
9	[CR13]	RF	K-shortest Path	Path Oriented	RF	SOP	Costo
10	[Kli13]	FF	Heurística	Path Oriented	GA	SOP	Uso de espectro
11	[WK13a]	Heurística	Búsqueda Tabú	Path Oriented	AFA	SOP	FS usados
12	[WGI13]			Path Oriented	AFA	SOP	FS usados
13	[WK13b]			Path Oriented		SOP	FS usados
14	[GKW14]	Búsqueda Tabú	Heurística	Path Oriented	FF	SOP	FS usados
15	[AW14]			Path Oriented	BF	SOP	Índice máx. de FS
16	[Tal+15]			Path Oriented	Programación Dinámica	SOP	FS usados
17	[Lez+16]	DE	BF	Path Oriented	MOP - Pareto	Índice máx. de FS/Distancia promedio	
18	[Kli+16]	Heurística Branch and cut and price		Path Oriented	SOP	FS usados	
19	[OFP16]	FF - RF	MOGA	Path Oriented	MOP - Suma Ponderada	Índice máx. de FS/Distancia total/Costo total	
20	[HH17]	FF	GA	Path Oriented	Heurística	SOP	Índice máx. de FS
21	[Hail17]	FF	MOGA	Path Oriented	MOP - Pareto	Índice máx. de FS/FS usados	
22	[Mar17]	FF	BCO	Path Oriented	FF	MOP - Pareto	Índice máx. de FS/-Distancia promedio
23	[OP17]	FF - RF	MOGA	Path Oriented	MOP - Suma Ponderada	Índice máx. de FS/Distancia total/Costo total	

Capítulo 3

Optimización Multi-Objetivo

3.1. Conceptos de Optimización Multi-Objetivo

Gran parte de los problemas del mundo real implican la optimización simultánea de varios objetivos que generalmente presentan conflictos entre ellos; es decir, la mejora en uno conduce al deterioro del otro [RKW09].

En los problemas de Optimización de un Solo Objetivo (SOP, *Single Objective Problem*) el resultado óptimo deseado está claramente definido. Sin embargo, dicho resultado no se obtiene fácilmente para los Problemas de Optimización Multiobjetivo (MOPs, *Multi-objective Optimization Problem*) donde, en vez de un único resultado óptimo, contamos con todo un conjunto de soluciones promisorias.

Un MOP se puede definir de varias maneras, por ejemplo se prioriza uno de los objetivos y los demás se colocan como restricciones, o también se genera un objetivo compuesto otorgando pesos a los objetivos en juego y armando una suma ponderada de los mismos [RR09].

Se dice que las soluciones de un problema con objetivos múltiples son óptimas porque ninguna otra solución es superior a ellas cuando se tienen en cuenta todos los objetivos y restricciones al mismo tiempo. Por ejemplo, ningún objetivo puede mejorarse sin degradar a los demás.

Al conjunto de estas soluciones óptimas se conoce como soluciones Pareto óptimas, en los cuales los problemas tienen múltiples objetivos a cumplir, y presentan conflictos al

realizar la optimización simultánea de los mismos. A partir de este concepto se establece, como requisito para afirmar que una situación es mejor que otra, el que en ella no se disminuya a nadie, pero se mejore a alguno; es decir que una situación será mejor que otra sólo si en la nueva es posible compensar las pérdidas de todos los perjudicados.

Previamente a la introducción del problema a tratar, se presenta una descripción formal de conceptos y terminología, de modo a facilitar las discusiones posteriores.

A partir de los conceptos introducidos, se define a un MOP de la siguiente manera:

Definición: MOP [Muh17]. Un MOP general incluye un conjunto de n parámetros (variables de decisión), un conjunto de l funciones objetivo, y un conjunto de r restricciones. Las funciones objetivo y las restricciones son funciones de las variables de decisión. Luego, el MOP puede expresarse como:

Optimizar:

$$y = f(x) = (f_1(x), f_2(x), \dots, f_l(x)) \quad (3.1)$$

sujeto a:

$$e(x) = (e_1(x), e_2(x), \dots, e_r(x)) \geq 0 \quad (3.2)$$

donde:

$$\begin{aligned} x &= (x_1, x_2, \dots, x_g) \in X \\ y &= (y_1, y_2, \dots, y_l) \in Y \end{aligned} \quad (3.3)$$

siendo x el vector de decisión e y el vector objetivo. El espacio de decisión se denota por X , y al espacio objetivo por Y . Optimizar, dependiendo del problema, puede significar igualmente, minimizar o maximizar.

El conjunto de restricciones $e(x) \geq 0$ determina el conjunto de soluciones factibles X_f y su correspondiente conjunto de vectores objetivo factibles Y_f .

De esta definición se tiene que cada solución del MOP en cuestión consiste de una g -tupla $x = (x_1, x_2, \dots, x_g)$, que conduce a un vector objetivo $y = (f_1(x), f_2(x), \dots, f_l(x))$, donde cada x debe cumplir con el conjunto de restricciones $e(x) \geq 0$. El problema de optimización consiste en hallar la x que tenga el “mejor valor” de $f(x)$. En general, y según ya se ha introducido, no existe un único “mejor valor”, sino un conjunto de soluciones. Entre éstas, ninguna se puede considerar mejor a las demás si se tienen en

cuenta todos los objetivos al mismo tiempo. Este hecho deriva de que puede existir, y generalmente existe, conflicto entre los diferentes objetivos que componen el problema. Por ende, al tratar con MOPs se precisa de un nuevo concepto de “óptimo”.

Definición 2: Conjunto de soluciones factibles [Muh17]. El conjunto de soluciones factibles X_f se define como el conjunto de vectores de decisión x que satisface los requerimientos $e(x)$:

$$X_f = \{x \in X \mid e(x) \geq 0\} \quad (3.4)$$

La imagen de X_f , es decir, la región factible del espacio objetivo, se denota por:

$$Y_f = f(X_f) = \{y = f(x) \mid x \in X_f\} \quad (3.5)$$

De estas definiciones se tiene que cada solución del MOP en cuestión consiste de una g -tupla $x = (x_1, x_2, \dots, x_g)$, que conduce a un vector objetivo $y = (f_1(x), f_2(x), \dots, f_l(x))$, donde cada x debe cumplir con el conjunto de restricciones $e(x) \geq 0$. El problema de optimización consiste en hallar la x que tenga el “mejor valor” de $f(x)$.

Los MOPs pueden ser resueltos con diferentes técnicas. Dichas técnicas pueden ser clasificadas en [Nar08]:

- Métodos Posteriori: usan información de preferencia de cada objetivo y generan iterativamente un conjunto Pareto de soluciones, explicado en la sección 3.1.1.
- Método A Priori: usan información de preferencia de cada objetivo y encuentran una solución de preferencia del conjunto Pareto, como por ejemplo el orden Lexicográfico [BW98], la técnica suma ponderada.

En este trabajo se utiliza la suma ponderada para resolver el MOP propuesto, ya que se trata de uno de los métodos más conocidos y de uso más extendido, que será explicado en la sección 3.1.2.

3.1.1. Concepto Pareto

Cuando se resuelven MOPs, debido a objetivos contradictorios, es posible obtener un conjunto de soluciones de compensación, denominado Conjunto Pareto en el espacio de decisión o Frente Pareto (PF , *Pareto Front*) en el espacio objetivo, en lugar de una única solución. En otras palabras, se dice que el conjunto de soluciones en PF no está dominado entre sí. Además, el conjunto de soluciones en el PF debe distribuirse uniformemente. En otras palabras, los algoritmos de optimización multiobjetivo deben alcanzar simultáneamente dos objetivos, a saber, la convergencia a PF y maximizar la diversidad en PF [RKW09].

A continuación se presenta una definición formal de conceptos clave y luego la definición del Frente Pareto, tomadas de la referencia [Sim13].

Definición: Dominancia Pareto en un contexto de Minimización. Sin pérdida de generalidad, un punto $a \in X$ se dice que domina a $b \in X$, y se denota por $a \succ b$, si las siguientes dos condiciones se cumplen:

$$f_i(a) \leq f_i(b) \quad \forall i, y \quad (3.6)$$

$$f_i(a) < f_i(b) \quad \text{para al menos una } i \quad (3.7)$$

Esto es, $a \in X$ es al menos igual de bueno que $b \in X$ en todas las funciones objetivo, y mejor que b en al menos una función objetivo.

Definición: Dominancia Leve. Un punto $a \in X$ se dice que domina levemente a $b \in X$, y se denota por $a \succeq b$, si:

$$f_i(a) \leq f_i(b) \quad \forall i \quad (3.8)$$

Esto es, a es al menos igual de bueno que b en todas las funciones objetivo.

Definición: No Dominado. Se dice que un punto $a \in X$ es no dominado si no existe un punto que lo domine en todo el espacio de búsqueda:

$$\nexists b \succ a \quad (3.9)$$

Definición: Punto Pareto. Un punto $a \in X$ es un punto Pareto si es un punto no dominado.

Definición: No comparables. Dos puntos, $a \in X$ y $b \in X$ son no comparables, y se denota por $a \sim b$, si $a \not\succ b$ y $b \not\succ a$.

Definición: Conjunto Pareto. El conjunto Pareto, denotado por P_c , es el conjunto de todos los puntos que son no dominados:

$$P_c = \{x : \nexists b \succ x \text{ con } b \in X\} \quad (3.10)$$

Nótese que $P_c \subseteq X$.

Definición: Frente Pareto. El Frente Pareto, denotado por P_f , es el conjunto de todos los vectores de funciones objetivo $f(x)$ correspondientes al conjunto Pareto:

$$P_f = \{f(x) : x \in P_c\} \quad (3.11)$$

3.1.2. Método de la suma ponderada

Este método es el más simple y probablemente el más ampliamente utilizado en la resolución de MOPs de los métodos a posteriori [Nar08]. El método de la suma ponderada realiza una reducción de las funciones objetivo a una única función objetivo mediante la suma de dichas funciones considerando un peso para cada una. Dicho peso es un valor parametrizado.

La reducción de las funciones objetivo en una sola función F , se realiza de la siguiente manera [RKW09]:

Optimizar:

$$F = \sum_{j=1}^l h_j f_j(x) \quad (3.12)$$

donde:

- los objetivos son normalizados
- $h_j \in [0, 1]$ es el peso usado para ponderar la j -ésima función objetivo
- $\sum_{j=1}^l h_j = 1$

El procedimiento es sencillo: se escoge una combinación de peso y se optimiza la función F para obtener una solución óptima. Otras soluciones surgen a partir de optimizaciones realizadas sobre una combinación de diferente de pesos.

Existe un teorema que sugiere que, para un MOP convexo, cualquier solución del Frente Pareto de dicho problema, puede ser conseguido mediante el método de suma ponderada, como se observa en la Figura 3.1. El teorema se enuncia como sigue:

Si x es una solución Pareto de un problema de optimización multi-objetivo convexo, entonces existe un vector h de pesos positivos distintos de cero, tal que x es una solución del problema [Mie99].

En la Figura 3.1 se puede observar el comportamiento que van teniendo los resultados obtenidos por la suma ponderada, dichos resultados son representados por las líneas a, b y x. El peso asignado a cada función objetivo tiene una directa relación con la pendiente de dichas líneas, y eso lo que determina el punto tangente al Frente Pareto, que representa la mejor solución proveída por el método de la suma ponderada.

La simplicidad y facilidad de uso, son algunas de las ventajas del método de la suma ponderada. Otra ventaja que se puede citar, como se mencionó anteriormente, es que este método garantiza encontrar soluciones del conjunto Pareto para MOPs convexos.

Este método también posee desventajas, entre las cuales podemos citar: se necesitan métodos auxiliares para encontrar los valores correctos de pesos para las funciones objetivo, para MOPs mixtos (minimización-maximización) se necesitan convertir todos los objetivos a un solo tipo, ya que para realizar la suma y reducir a una única función, se necesita manejar un solo contexto de maximización o minimización. Además, en la

Figura 3.2 se puede apreciar otra desventaja del método, si el MOP no es convexo, no se garantiza encontrar la mejor solución en la dirección definida por los pesos.




FIGURA 3.1: Método de la suma ponderada sobre el Frente Pareto en un MOP convexo.
[Nar08]

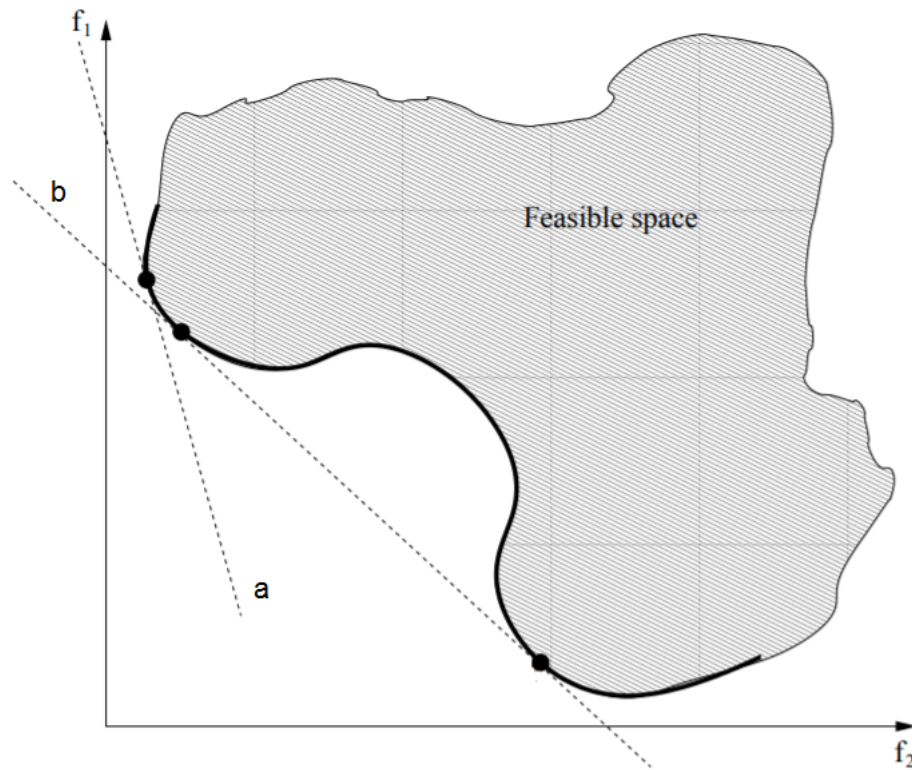


FIGURA 3.2: Método de la suma ponderada sobre el Frente Pareto en un MOP no convexo. [Nar08]

3.2. Clasificación de problemas de optimización

Los problemas de optimización pueden clasificarse de varias maneras, teniendo en cuenta distintos enfoques. A continuación se describen algunos de los enfoques para clasificación de problemas de optimización basados en [RR09].

Cualquier problema de optimización puede clasificarse como restringido o no restringido, dependiendo de si existen restricciones en el problema o no, respectivamente.

Otra clasificación importante de los problemas de optimización se basa en la naturaleza de las expresiones para la función objetivo y las restricciones. De acuerdo con esta clasificación, los problemas de optimización pueden clasificarse como problemas de Programación Lineal (LP, *Linear Programming*) y no Programación No Lineal (NLP, *No Linear Programming*). Si la función objetivo y todas las restricciones de la ecuación de un problema son funciones lineales de las variables de diseño, el problema de programación matemática se denomina problema de LP. Por otro lado, si alguna de las funciones

objetivo y de restricción de la ecuación del problema no es lineal, el problema se denomina problema de NLP, este es el problema de programación más general y ciertos tipos de problemas pueden considerarse como casos especiales del problema de NLP, tal como la programación geométrica.

Sobre la base de la naturaleza determinista de las variables involucradas, los problemas de optimización pueden también clasificarse como problemas deterministas y estocásticos. Un problema de programación estocástico es un problema de optimización en el cual algunos o todos los parámetros (variables de diseño y / o parámetros preasignados) son probabilísticos (estocásticos o no deterministas).

Uno de los enfoques más importantes de clasificación de los problemas de optimización es según la cantidad de objetivos. Dependiendo del número de funciones objetivo a minimizar, los problemas de optimización pueden clasificarse como problemas de programación mono-objetivo y multi-objetivo.

En este trabajo, se aborda el problema RSA como un problema de optimización restringido, de programación lineal, estocástico y multi-objetivo.

3.3. Métodos para resolución de MOPs: Métodos exactos

Numerosos métodos clásicos existen para el tratamiento de MOPs como problemas Mono-objetivo [Bañ06]. Todos ellos se caracterizan por operar en dos fases. Primeramente generan, a partir del problema de objetivos múltiples, un SOP. En la segunda fase aplican un método de optimización tradicional al SOP generado en la fase anterior y obtienen sus resultados. Ambas fases son independientes entre sí.

Varios tipos de métodos se emplean para la reducción realizada en la primera fase [HL92], [Coe00a], cada uno de ellos tiene sus propias ventajas y desventajas. En gran parte de ellos, la técnica consiste en disponer de las funciones objetivo de modo tal que se puedan unir en una única función parametrizada, mientras el proceso de optimización se aplica sobre esta única función. Generalmente, los parámetros de la función se varían de modo sistemático y se requieren múltiples corridas del procedimiento de optimización (2da. fase) para conseguir un conjunto que se aproxime al conjunto Pareto óptimo real.

En lo que respecta a los métodos de solución para abordar problemas como el RSA, existen dos grandes categorías, las cuales pueden ser agrupadas de la siguiente manera: métodos exactos y heurísticas [RR09].

Los métodos exactos garantizan una solución óptima usando programación matemática y algoritmos exactos para la exploración de grafos. Son eficientes generalmente en problemas pequeños debido a restricciones de tiempo computacional [AGP10].

Por medio de estas técnicas se busca obtener el mayor beneficio en sistemas de diferentes tipos. Si una de las funciones, objetivo o de restricciones, es no lineal, el problema es llamado NLP. Este es el problema de programación más general, todas las demás pueden considerarse un caso especial de NLP. Si la función objetivo y todas las restricciones del problema son funciones lineales de las variables de diseño, el problema de programación matemático es un problema LP.

Sin pérdida de generalidad, un problema de LP consiste en minimizar la función [GM86]:

$$z = F(x_1, x_2, \dots, x_g) = w_1x_1 + w_2x_2 + \dots + w_gx_g \quad (3.13)$$

Sujeto a:

$$\begin{aligned} u_{11}x_1 + u_{12}x_2 + \dots + u_{1g}x_g &\geq v \\ u_{21}x_1 + u_{22}x_2 + \dots + u_{2g}x_g &\geq v_2 \\ &\dots \\ u_{r1}x_1 + u_{r2}x_2 + \dots + u_{rg}x_g &\geq v_r \\ x_1, x_2, \dots, x_g &\geq 0 \end{aligned} \quad (3.14)$$

A la función $z = F(x_1, x_2, \dots, x_g) = w_1x_1 + w_2x_2 + \dots + w_gx_g$ se le denomina función objetivo o función criterio.

Los coeficientes w_1, w_2, \dots, w_n son números reales y se llaman coeficientes de beneficio o coeficientes de costo. Son datos de entrada del problema.

x_1, x_2, \dots, x_g son las variables de decisión (o niveles de actividad) que deben determinarse.

Las desigualdades $u_{i1}x_1 + u_{i2}x_2 + \dots + u_{ig}x_g \geq v_i$, con $i = 1, \dots, r$ se llaman restricciones.

Los coeficientes u_{ij} , con $i = 1, \dots, r$ y $j = 1, \dots, g$ son también números reales conocidos y se les denomina coeficientes tecnológicos.

El vector del lado derecho, es decir los términos v_i , con $i = 1, \dots, r$ se llama vector de disponibilidades o requerimientos y son también datos conocidos del problema.

Las restricciones $x_j \geq 0$ con $j = 1, \dots, g$ se llaman restricciones de no negatividad.

Al conjunto de valores de (x_1, x_2, \dots, x_g) que satisfacen simultáneamente todas las restricciones se le denomina región factible. Cualquier punto dentro de la región factible representa un posible programa de acción.

La solución óptima es el punto de la región factible que hace máxima o mínima la función objetivo.

Según los valores que puedan tomar las variables de diseño del problema, nuevamente los problemas de LP pueden clasificarse en Programación Lineal Entera (ILP, *Integer Linear Programming*) [Sch98] y Programación Lineal Binaria (BLP, *Binary Linear Programming*) [FWK05]. Si algunas o todas las variables de diseño de un problema de optimización x_1, x_2, \dots, x_g son limitadas a tomar solo valores enteros, el problema es llamado ILP. En cambio si las variables de diseño solo pueden tomar valores binarios (0, 1) el problema es llamado BLP.

3.4. Métodos para resolución de MOPs: Heurísticas

En los MOPs, se utilizan heurísticas como los Algoritmos Evolutivos (EA, *Evolutionary Algorithm*) y GA, entre otras [RR09]. Los términos EA y GA se refieren a técnicas de búsqueda y optimización inspiradas en el modelo de la evolución propuesto por Charles Darwin [Can04].

3.4.1. Algoritmos Evolutivos

En la naturaleza los individuos se caracterizan mediante cadenas de material genético que se denominan cromosomas. En los cromosomas se halla codificada toda la información relativa a un individuo y a sus tendencias. Cada individuo posee un nivel de

adaptación al medio que lo dota de mayor capacidad de sobrevivencia y generación de descendencia. Tal nivel de adaptación está ligado a las características que están codificadas en sus cromosomas. Como el material genético puede transmitirse de padres a hijos al ocurrir el apareamiento, los hijos resultantes poseen cadenas de cromosomas parecidas a las de sus padres y combinan las características de los mismos. Por tanto si padres con buenas características se cruzan, posiblemente generarán hijos igualmente buenos o incluso mejores [CLVV+07].

Para resolver un problema de búsqueda u optimización utilizando EA y los conceptos sugeridos, primero se representa como individuos de una población finita a un número dado de soluciones posibles del problema, a este proceso se denomina codificación. En la codificación de un individuo debe estar presente toda la información relevante del mismo y que se considera que influye en la optimización o búsqueda.

Luego, se determina el nivel de aptitud o adaptación de cada individuo (fitness), dependiendo de la calidad de la solución que representa. Posteriormente los individuos existentes generan a otros individuos mediante los operadores genéticos como selección, cruzamiento y mutación. El operador de selección elige los padres que se cruzarán. La probabilidad de que un individuo sea escogido como padre y/o que sobreviva hasta la siguiente generación está ligada a su fitness o aptitud: a mayor fitness, mayor probabilidad de sobrevivencia y de tener descendientes, de la misma forma que ocurre en los procesos naturales.

Luego de escogerse los padres, se procede a la recombinación o cruzamiento de los mismos para obtener a la nueva generación. De esta manera, en cada nueva generación se tienen buenas probabilidades de que la población se componga de mejores individuos, ya que los hijos heredarán las características buenas de sus padres, y al combinarlas podrán ser aún mejores.

Por otro lado, durante la recombinación pueden ocurrir alteraciones (mutaciones) en la información genética de un individuo. Si tales alteraciones se producen para bien, originarán un individuo bueno con alto fitness y la alteración se transmitirá a los nuevos individuos; si el cambio no es benéfico, el individuo alterado tendrá un fitness bajo y poca o ninguna descendencia, con lo que la alteración prácticamente morirá con él. De esta manera, luego del curso de varias generaciones, la población habrá evolucionado

hacia individuos genéticamente muy parecidos y que tienen un nivel de aptitud elevado, es decir, representan buenas soluciones al problema propuesto.

Los operadores descritos reciben el nombre de operadores de búsqueda u operadores genéticos. La reproducción enfoca la atención en los individuos con alto fitness, y de esta manera explota la información disponible sobre la adaptación del individuo al medio ambiente. La recombinación y la mutación perturban de alguna manera a los individuos y proveen así de heurísticas para la exploración del espacio de búsqueda. Por ello se dice que los EAs utilizan conceptos de explotación y exploración.

Un paradigma de los EA ampliamente estudiado y utilizado para resolución de problemas de gran tamaño, es el de GA, que será descrito con más detalle en la sección 3.4.2, por ser el seleccionado para el desarrollo de este trabajo.

3.4.2. Algoritmos Genéticos

Los GA se utilizan en varios ámbitos, principalmente para búsquedas y optimizaciones en el contexto mono-objetivo. En la práctica se implementa el algoritmo escogiendo una codificación para las posibles soluciones del problema. La codificación se realiza mediante cadenas de bits, números, caracteres y otras estructuras para representar a los cromosomas. Luego, las operaciones de cruzamiento y mutación se aplican de manera muy sencilla mediante funciones de manipulación de valores de vectores.

El ciclo de trabajo de un GA es generalmente el siguiente: generar una población inicial, calcular el fitness de los individuos en la población, crear una nueva población mediante selección, cruzamiento y mutación, y, finalmente, descartar la población vieja y seguir iterando utilizando la población recién creada. A cada iteración de este ciclo se la conoce como una generación [SD94].

La primera generación (generación 0) de este proceso, generalmente opera sobre una población de individuos generados al azar. A partir de allí, los operadores genéticos se aplican para mejorar a la población. El Algoritmo 1, presentado a continuación, muestra el algoritmo principal [SD94].

El operador de selección, según se ha apuntado, simula el proceso de selección natural en que el más fuerte tiene mayor capacidad de supervivencia. En el GA la capacidad

Algoritmo 1 Algoritmo Genético básico

-
- 1: *InicializarPoblacion* $P(t)$ /* inicializar una población de individuos generados al azar */
 - 2: *EvaluarPoblacion* $P(t)$ /* evaluar el fitness de todos los individuos de la población inicial */
 - 3: **mientras** No se cumple el criterio de parada **hacer**
 - 4: $P' = \text{SeleccionarPadres } P(t)$ /* seleccionar una poblacion para generar descendientes */
 - 5: *Recombinar* $P'(t)$ /* recombinar los “genes” del grupo de padres seleccionados */
 - 6: *Mutar* $P'(t)$ /* perturbar la población generada de manera estocástica */
 - 7: *Evaluar* $P'(t)$ /* calcular las funciones objetivo de la población recién creada */
 - 8: $P = \text{Sobrevivientes } P, P'(t)$ /* Seleccionar sobrevivientes para la siguiente generación */
 - 9: **fin mientras**
-

de supervivencia de un individuo está ligada al valor numérico de la función objetivo o fitness. Este operador se aplica a cada iteración sobre una población de individuos de tamaño constante, con el objetivo de seleccionar individuos prometedores para generar la nueva población. Entre los individuos seleccionados pueden hallarse dos o más individuos idénticos, esto se debe a que los individuos con bajo fitness tienen poca probabilidad de ser elegidos, mientras que los de buen fitness son seleccionados con mayor frecuencia.

El operador de selección puede aplicarse de maneras diversas. Unas veces se realiza la selección mediante torneos en los cuales se escoge al azar un grupo de individuos y gana el torneo aquel con mejor fitness. La cantidad de individuos que se escogen para la competencia se fija de antemano y permanece constante en la implementación tradicional. Esta forma de selección recibe el nombre de selección por torneos y refleja de manera más adecuada el proceso natural de selección. Otra forma, conocida como selección de ruleta, es fácilmente comprensible imaginando una ruleta en la que el número de partes en que se divide la misma es igual a la cantidad de individuos de la población, siendo el tamaño de cada parte proporcional al fitness de cada individuo. Es de esperar que al hacer girar la ruleta varias veces, se obtendrá mayor cantidad de individuos con alto fitness. Aunque pueden existir otras formas de realizar la selección [Bañ06], las dos anteriormente mencionadas son las más comunes en las implementaciones publicadas.

Una vez seleccionados los individuos se aplica a cada par de ellos el operador de cruzamiento. También existen diferentes métodos para aplicar el operador de cruzamiento [Bañ06]. La forma más utilizada para aplicar cruzamiento es el corte de puntos. En el

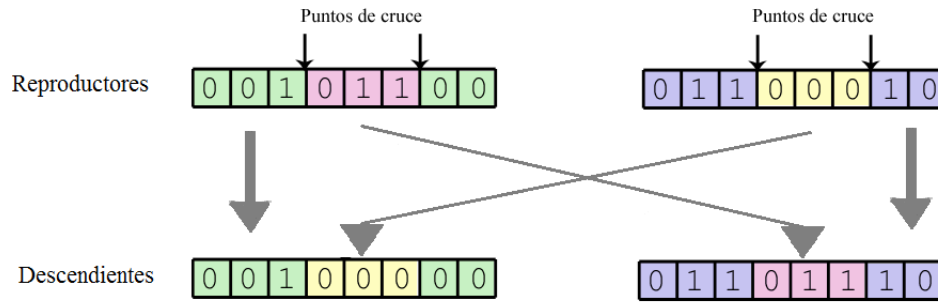


FIGURA 3.3: Operador cruce de 2 puntos para un GA.

mismo, se definen la cantidad de puntos a utilizar, es decir, cuantos cortes se realizará a los reproductores, dicha cantidad también se mantiene constante a lo largo de la ejecución del algoritmo. Luego se escogen aleatoriamente los puntos de corte que se aplicarán al par de cromosomas o reproductores seleccionados. Para generar los dos nuevos individuos, cada sección generada por los cortes de cada reproductor son insertados a los dos nuevos individuos de forma intercalada, de esta manera, cada individuo generado a partir del operador cruce, posee partes de los genes de sus dos reproductores. En la Figura 3.3 se puede observar este proceso, donde tenemos 2 puntos de corte en cada reproductor. Dichos puntos indican los segmentos de cada reproductor que se asignarán a cada hijo.

El operador de cruzamiento representa una forma de búsqueda local, en las inmediaciones del espacio de búsqueda que rodea a los padres. Por su parte, el proceso de mutación es básicamente una búsqueda aleatoria. Se selecciona aleatoriamente una posición específica dentro de cromosoma del individuo a mutar, para luego cambiar el valor contenido en dicha posición. Como en la naturaleza, la probabilidad de que ocurra una mutación es pequeña, en las condiciones de vida normales. En el GA se trata de representar lo mismo, con un valor de ocurrencia muy bajo para el operador de mutación.

Una vez generado el nuevo conjunto de individuos, se seleccionan los más aptos para conformar la nueva población y dar paso a la siguiente generación, donde se repite el proceso.

Como se mencionó anteriormente, este proceso se realiza tantas generaciones sean necesarias para completar el criterio de parada establecido, el cual puede ser un tiempo límite de ejecución, una cantidad definida de generaciones, etc. [Flo11]

Al término del proceso, la mejor solución calculada es la que se retorna como solución final.

3.4.3. Algoritmos Genéticos Multi-objetivos

Dentro de las técnicas meta-heurísticas mejor situadas para explorar el Frente Pareto, se encuentran los algoritmos evolutivos (EAs) [CLVV+07]. Debido a su inherente paralelismo y a su capacidad para explotar las similitudes de las soluciones mediante recombinación, los EAs son capaces de aproximar el frente de Pareto en una sola ejecución. El potencial de los algoritmos evolutivos para resolver MOPs se remonta a la tesis doctoral de Rosenberg [Ros70], en la cual se sugería el uso de GAs.

Los EAs hacen uso de los conceptos de *Asignación de Jerarquía* y *Selección basada en no dominancia* para tratar un MOP [Bañ06]. La idea básica es encontrar un conjunto de soluciones en la población que sean no dominadas (Selección basada en no dominancia). A estas soluciones se les asigna entonces la jerarquía más alta y se eliminan de la población. De la población restante se obtiene otro conjunto de soluciones no dominadas, a las que se les asigna la siguiente jerarquía en turno. Este proceso se repite hasta que toda la población esté jerarquizada (Asignación de jerarquía).

En [FF+93] se propuso el Algoritmo Genético Multi-objetivo (MOGA, *Multi-objective Genetic Algorithm*), en el cual, la jerarquía de un cierto individuo se determina en función del número de cromosomas por los cuales es dominado en la población actual.

En MOGA, la evaluación de los individuos en la población, se realiza mediante el valor llamado Fitness, el cual puede ser determinado de dos maneras: mediante la evaluación de su jerarquía o en función de los valores de las funciones objetivo. En la primera, se ordena la población mediante la jerarquía y se asigna el fitness a los individuos interpolando entre el mejor y el peor individuo, de acuerdo a alguna función [Gol06]. En [BT95] se demostró que este tipo de asignación de fitness, puede producir convergencia prematura. La segunda manera de asignación de fitness, evalúa las funciones objetivo para cada individuo y utiliza dichos valores para asignar el fitness [Coe00b].

El primer tipo de asignación de fitness, está enfocado únicamente a soluciones de MOPs mediante Frente Pareto, y el segundo puede ser aplicado a otras técnicas de solución de MOPs, no basadas en dominancia, como la suma ponderada.

Parte II

Trabajo propuesto

Capítulo 4

Programación Lineal Entera Multi-objetivo

En este trabajo se utiliza el método de ILP, es decir, se propone un modelo ILP para resolución del problema abordado, basado en suma ponderada, siguiendo el modelo propuesto en [\[LK15\]](#).

4.1. Planteamiento del problema

En EONs basados en OFDM, la demanda de tráfico entre el par de nodos fuente y de destino es transmitida a través de múltiples subportadoras de baja velocidad. Dada la topología física, la matriz de demandas y una lista de rutas precalculadas (K-shortest path), necesitamos:

- Satisfacer todas las demandas de conexión fuente-destino: determinar la ruta y la asignación de espectro para cada demanda de tráfico.
- Optimizar la utilización del espectro: minimizar el Máximo FS utilizado sobre todas las fibras de la red.
- Optimizar la distancia recorrida: minimizar la suma de la distancia total recorrida.
- Optimizar el costo total: minimizar el costo total, en función a la distancia recorrida y los FS solicitados.

Los siguientes supuestos son establecidos para el modelo propuesto:

- El recurso espectral de cada fibra óptica se divide en FSs.
- La capacidad de la fibra en términos de FS está limitada en todos los enlaces;
- Las demandas de conexión son bidireccionales, y debe encontrarse una ruta óptica completa de extremo a extremo para cada demanda;
- No se da ninguna ruta específica para una conexión de antemano, es decir, cualquier ruta posible de las rutas precalculadas y cualquier conjunto posible de FS contiguos se evaluarán mientras se resuelve el modelo.
- La solicitud está representada por tres tuplas: (s, d, α_{sd}) , incluyendo el nodo fuente s , el nodo de destino d , y el ancho de banda/velocidad de datos demandada α considerada en cantidad de FS solicitados.

4.2. Formulación MOILP

Dados:

G	: Grafo de la red, que representa a una EON
E	: Conjunto de enlaces, en G
V	: Conjunto de vértices, en G
GB	: Cantidad de FS para Banda Guarda
F_{total}	: Cantidad de FS que posee la fibra
P	: Conjunto de rutas
K	: Cantidad de rutas disponibles
SD	: Cantidad de demandas

Las notaciones y la formulación se presentan a continuación:

Constantes:

$distanciaMaxima$: Distancia máxima recorrida considerando las rutas más largas
$espectroMaximo$: Índice del máximo FS disponible
$costoMaximo$: Costo total de las solicitudes considerando sus distancias máximas
$dist_p^{sd}$: Distancia de la ruta p
α_{sd}	: Cantidad de FS solicitados por la solicitud sd donde $s, d \in V$

Índices:

sd : Índice de demandas, $sd \in \{1, 2, \dots, SD\}$

p : Índice de rutas, $p \in \{1, 2, \dots, K\}$

mn : Índice de enlace direccional, $m \neq n$

Variables:

x_p^{sd} : 1 si la ruta p es utilizada para atender la solicitud sd , 0 en otro caso

Λ_{sd} : Primer FS asignado a la solicitud sd , $sd \in \{0, \dots, F_{total} - 1\}$

$\delta_{sd,s'd'}$: Indicador que es igual a 0 si $\Lambda_{s'd'} < \Lambda_{sd}$, y 1 en caso contrario (es decir, $\Lambda_{s'd'} > \Lambda_{sd}$)

Función Objetivo a minimizar:

$$f(x) = f_1 + f_2 + f_3 \quad (4.1)$$

sueto a:

$$f_1 \geq \frac{\sum_{sd} \sum_p (dist_p^{sd} \cdot x_p^{sd})}{distanciaMaxima} \quad (4.2)$$

$$f_2 \geq \frac{\max_{\forall sd} (\Lambda_{sd} + \alpha_{sd})}{espectroMaximo} \quad (4.3)$$

$$f_3 \geq \frac{\sum_{sd} \sum_p (\alpha_p^{sd} \cdot dist_p^{sd} \cdot x_p^{sd})}{costoMaximo} \quad (4.4)$$

$$\sum_{p \in P_{sd}} x_p = 1, \forall (s, d) \quad (4.5)$$

$$\Lambda_{sd} + \alpha_{sd} \cdot x_p^{sd} + GB - \Lambda_{s'd'} \leq (F_{total} + GB) \cdot (1 - \delta_{sd,s'd'} + 2 - x_p^{sd} - x_{p'}^{s'd'}) \quad (4.6)$$

$$\Lambda_{s'd'} + \alpha_{s'd'} \cdot x_{p'}^{s'd'} + GB - \Lambda_{sd} \leq (F_{total} + GB) \cdot (1 - \delta_{s'd',sd} + 2 - x_p^{sd} - x_{p'}^{s'd'}) \quad (4.7)$$

$$\delta_{sd,s'd'} + \delta_{s'd',sd} = 1 \quad (4.8)$$

$$\Lambda_{s'd'} - \Lambda_{sd} < F_{\text{total}} \cdot \delta_{sd,s'd'} \quad (4.9)$$

$$\Lambda_{sd} - \Lambda_{s'd'} < F_{\text{total}} \cdot \delta_{s'd',sd} \quad (4.10)$$

La restricción (4.2) representa la distancia recorrida, la restricción (4.3) representa el espectro máximo utilizado, y la (4.4) representa el costo total.

Por otro lado, se tiene que, para todas las solicitudes $sd, s'd'$ y los caminos $p \in P_{sd}$ y $p' \in P_{s'd'}$, con p y p' compartiendo al menos un enlace común mn las restricciones (4.5), (4.6), (4.7), (4.8), (4.9) y (4.10) aseguran el cumplimiento de las restricciones de capa física.

Las restricciones (4.5), (4.6) y (4.7) aseguran que las porciones del espectro que se asignan a las conexiones que utilizan caminos que comparten un enlace común no se superpongan y sean adyacentes.

Además, para todas las solicitudes $sd, s'd'$ que tienen $p \in P_{sd}$ y $p' \in P_{s'd'}$, con p y p' compartiendo al menos un enlace común ($\exists mn : nm \in p \wedge mn \in p'$), las restricciones (4.8), (4.9) y (4.10) aseguran que, o bien $\delta_{sd,s'd'} = 1$ significa que la frecuencia inicial Λ_{sd} es más pequeña que la frecuencia inicial $\Lambda_{s'd'}$, esto es, $\Lambda_{sd} < \Lambda_{s'd'}$, o $\delta_{s'd',sd} = 1$, en cuyo caso $\Lambda_{sd} > \Lambda_{s'd'}$. Note que Λ_{sd} y $\Lambda_{s'd'}$ son siempre acotados superiormente por F_{total} , y que por lo tanto su diferencia será siempre menor que F_{total} .

4.3. Ejemplo numérico

Tomemos como ejemplo la topología mostrada en la Figura 4.1 con 2 solicitudes: *Solicitud* 1, con nodo fuente 0 y nodo destino 1; y la *Solicitud* 2, con 0 y 2 como nodos fuente y destino respectivamente, solicitando ambas demandas una cantidad de 2 FS. La tabla de ruteo para ambas solicitudes está representada en la Tabla 4.1 con $k = 2$. Asumiendo

TABLA 4.1: Tabla de ruteo para la topología de 5 nodos con $K = 2$.

	Demanda	Ruta
0	01	0-1
1	01	0-4-3-1
2	02	0-1-2
3	02	0-1-3-2

que la *Solicitud* 1 fue atendida con la ruta 0 y los FS 0 y 1, y que la *Solicitud* 2 fue atendida con la ruta 2 y los FS 3 y 4, tenemos entonces el desarrollo de las restricciones.




FIGURA 4.1: Topología de 5 nodos

Para la *Solicitud* 1 se utiliza la ruta 0, tenemos entonces que $x_0 = 1$ y $x_1 = 0$, lo cual cumple la restricción (4.5). Luego, tenemos que $\delta_{01,02} = 1$ ya que $\Lambda_{02} > \Lambda_{01}$ como se observa en la Figura 4.2.

Al observar la Figura 4.2, como la frecuencia inicial de *Solicitud* 2 es mayor que la frecuencia inicial de *Solicitud* 1, tenemos que $\delta_{01,02} = 1$, lo que da como resultado de la diferencia entre Λ_{02} y Λ_{01} un valor menor a F_{total} . Con estos mismos valores también se cumple la restricción (4.10).

Para considerar la contigüidad del espectro de las demandas, tenemos que $\Lambda_{01} + \alpha_{01} \cdot x_0 + GB - \Lambda_{02} = -2$, que es un valor menor a $(F_{total} + GB) \cdot (1 - \delta_{01,02} + 2 - x_1 - x_2) = 0$, como $\delta_{01,02} = 1$, y se puede observar que se cumple la restricción.




FIGURA 4.2: Representación del enlace 0-1 atendiendo 2 solicitudes.

Ahora bien, evaluemos las funciones objetivo con los valores asignados.

Para la función de distancia total (4.2), tenemos que la suma de las distancias de las rutas utilizadas para ambas demandas da 3, y la *distanciaMaxima* es 6, lo que da un valor resultante de 0,5.

Para la restricción (4.3), máximo FS utilizado, tenemos que el máximo FS de la red es 4, y el máximo FS utilizado por la solución es también 4, lo que da un valor resultante de 1.

Por último, para la función objetivo de costo total (4.4), tenemos que el *costoMaximo* es 12, y la solución retorna un costo total de 6, lo que da como resultado un valor de 0,5.

Finalmente, la suma de los 3 valores obtenidos es 2, siendo este el resultado final. Se puede observar que, el valor máximo posible es 3, ya que existen 3 funciones objetivo, y el modelo propuesto reduce dicho valor a 2, logrando minimizar el valor total.

Capítulo 5

GA Multi-Objetivo

En este capítulo, se presenta el algoritmo denominado Multi-Objective GA (MOGA) para la resolución del problema RSA offline en una red EON. En lo que sigue, se describe el enfoque utilizado para resolver el problema y luego los detalles de implementación del MOGA.

Vale la pena mencionar que al minimizar el índice el máximo FS utilizado, se reduce la fragmentación de los recursos de espectro, que es uno de los objetivos en EON [Pat+11b].

5.1. Implementación del MOGA

El algoritmo MOGA comienza con la creación de la población inicial. Las mejores soluciones se encuentran a lo largo de varias generaciones. Los operadores tales como cruce y mutación exploran otras posibles soluciones. En nuestro enfoque, no todos los individuos son soluciones viables, por lo tanto, se requieren procedimientos adicionales de manejo de restricciones. Cuando se cumple el criterio de parada, se encuentra una solución relativamente buena.

En esta implementación, el objetivo es encontrar la ruta y el conjunto de FS para cada solicitud tal que, se minimicen la distancia total recorrida, el máximo FS utilizado y el costo total y que a la vez cumplan las restricciones de RSA.

A continuación se describen en detalle las partes de la implementación del MOGA propuesto en este trabajo, dados en los Algoritmos 2, 3 y 4.

Algoritmo 2 MOGA

ENTRADA: Tabla de rutas P; Cantidad total de FS; Lista de demandas; Tamaño de la población; Probabilidad de mutación; Criterio de Parada; Algoritmo de Asignación de FS; Distancia Total, FS Máximo, Costo Máximo

SALIDA: Mejor solución

- 1: InicializarPoblacion(P)
- 2: EvaluarPoblacion(P)
- 3: **mientras** No se cumple el criterio de parada **hacer**
- 4: P' = SeleccionarPadres(P)
- 5: N = Cruce(P')
- 6: N' = Mutar(N)
- 7: S = AsignaciónDeEspectro(N')
- 8: S' = EvaluarPoblación(S)
- 9: P = SeleccionarMejoresIndividuos(S',P)
- 10: **fin mientras**
- 11: Retornar MejorSolución(P)

Algoritmo 3 Evaluación de población

ENTRADA: Población P

SALIDA: Población evaluada

- 1: **para** cada *Individuo* \in P **hacer**
- 2: Fitness = EvaluarIndividuo(Individuo)
- 3: ActualizarFitness(Individuo, Fitness)
- 4: **fin para**
- 5: Retornar Población

Algoritmo 4 Evaluación de individuo

ENTRADA: Individuo; Distancia Máxima; FS Máximo; Costo Máximo; Tabla de rutas P

SALIDA: Fitness f ; Distancia f_1 ; Espectro f_2 , Costo f_3

- 1: Distancia = 0
- 2: FSMayor = 0
- 3: **para** Gen \in Individuo **hacer**
- 4: Distancia = Distancia + DistanciaRuta(Gen, P)
- 5: **si** FSMayor \leq ÚltimoFS(Gen) **entonces**
- 6: FSMayor = ÚltimoFS(Gen)
- 7: **fin si**
- 8: Costo = Costo + Costo(Gen, P)
- 9: **fin para**
- 10: f_1 = Distancia / Distancia Máxima
- 11: f_2 = FSMayor / FS Máximo
- 12: f_3 = Costo / Costo Máximo
- 13: $f = f_1 + f_2 + f_3$
- 14: retorna f, f_1, f_2, f_3

TABLA 5.1: Tabla de ruteo para la topología de 5 nodos con $K = 3$.

	Demanda	Ruta
0	01	0-1
1	01	0-4-3-1
2	02	0-1-2
3	02	0-1-3-2
4	41	4-0-1
5	41	4-3-1

5.1.1. Representación

En el MOGA presentado en este trabajo, el cromosoma representa un conjunto de solicitudes atendidas.

Básicamente el cromosoma es un vector compuesto en el cual cada gen representa una solicitud atendida. Cada elemento de dicho vector contiene: el índice de la ruta asignada (tomada de la tabla de rutas precalculadas), y el índice inicial de los FS asignados a la solicitud.

En la Figura 5.1 se puede observar la representación de un cromosoma, que utiliza la Tabla 5.1 de rutas precalculadas, tomando como ejemplo la topología 5-nodos 4.1 con $K = 3$. Vemos que el primer gen representa al índice de la demanda 0 – 1, utiliza la ruta de la posición 0 de la Tabla 5.1 y se le asignaron los FS solicitados a partir del FS de la posición 0. En el segundo gen, se representa la demanda 0 – 2, utiliza la ruta de la posición 2 y el primer FS asignado es 3. Luego para la demanda 0 – 3 utiliza la ruta 5 con el primer FS 0.




FIGURA 5.1: Representación del cromosoma utilizado.

5.1.2. Población Inicial

Como se muestra en el Algoritmo 2, el primer paso es inicializar la población. El MOGA inicia con una población inicial de cromosomas, definida como se explica a continuación.

El algoritmo atiende las solicitudes en un orden determinado, el cual fue tomado de un trabajo presentado anteriormente en la literatura [CR13]. En dicho trabajo, el orden es definido como sigue: se ordenan las solicitudes de mayor a menor, definido por el mayor costo posible de dicha solicitud, el primer 30 % de dicha lista es atendido en primer lugar, mientras que el 70 % restante es atendido de forma aleatoria. Este orden es representado por las posiciones de los genes en el cromosoma y se mantiene durante toda la ejecución el algoritmo. Luego, se asignan de forma aleatoria las rutas y FS a las demandas, teniendo en cuenta el orden previamente definido. Cada cromosoma codifica una solución válida.

5.1.3. Evaluación de Población

Luego de inicializar o evolucionar la población, se evalúa dicha población, como se observan en el paso 2 y 8 del Algoritmo 2. En este trabajo se propone un MOGA mediante una suma ponderada, en la cual se consideran tres objetivos a minimizar. Para implementar la suma ponderada de las 3 funciones objetivo, se utilizó el mismo peso para cada función, ya que el objetivo de este trabajo es mostrar el comportamiento de una heurística para la resolución del problema RSA considerando más de un valor a optimizar, y no la importancia de cada valor propuesto.

Las funciones objetivo a minimizar son la distancia recorrida, el máximo FS utilizado, y el costo total. Con el fin de conducir la búsqueda hacia mejores soluciones, se utiliza como valor Fitness de la implementación, la suma ponderada de las funciones objetivo, normalizando dichos valores.

Finalmente, el valor del fitness se calcula como:

$$f = f_1 + f_2 + f_3 \quad (5.1)$$

y los individuos con mejor valor de fitness (valores menores de f , por el enfoque de minimización) serán seleccionados para la próxima generación.

Para poder realizar la suma ponderada, hay que mencionar que los valores f_1 , f_2 y f_3 son valores normalizados de las funciones objetivo, presentados en (4.2), (4.3) y (4.4) respectivamente. Este proceso se observa en los Algoritmos 3 y 4.

5.1.4. Selección de cromosomas para la siguiente generación

El Algoritmo 2 nos muestra que el ciclo inicia con la selección de padres, en el paso 4.

Se utiliza el método de muestreo estocástico universal [GM17] para seleccionar dos padres para producir nuevos individuos para la próxima generación.

El muestreo estocástico universal es un algoritmo de muestreo que se implementa en una sola fase. Dado un conjunto de n individuos y sus valores objetivos asociados, el algoritmo los acomoda en una ruleta donde el tamaño de los cortes asignados a cada individuo es proporcional al valor objetivo. Después, una segunda ruleta, es marcada con y marcadores igualmente espaciados entre si, donde y es el número de selecciones que deseamos efectuar. Por ultimo se gira la ruleta y se selecciona un individuo por cada marcador. Las posiciones de los marcadores indican los individuos seleccionados.

5.1.5. Cruzamiento

Se denomina operador de cruce a la forma de calcular el cromosoma del nuevo individuo en función del cromosoma del padre y de la madre. El operador de cruce es fuertemente responsable de las propiedades del MOGA, y determinará en gran medida la evolución de la población y se aplica en el paso 5 del Algoritmo 2

En este trabajo se utilizó el operador de cruzamiento de dos puntos [GM17] mediante el cual se generan aleatoriamente dos puntos de corte en cada reproductor, utilizando ambos los mismos puntos generados, asignando intercaladamente cada segmento generado de los padres a cada hijo. En la Figura 5.2 se puede observar el procedimiento de cruce, en el cual los puntos de corte generados aleatoriamente fueron el 1 y el 2. El primer segmento del reproductor 1 es asignado al primer segmento del primer descendiente, y el primer segmento del reproductor 2 es asignado al primer segmento del segundo descendiente. Luego, el segundo segmento del reproductor 1 es asignado al segundo descendiente, mientras que el segundo segmento del reproductor 2 se asigna como segundo segmento del primer descendiente. Los últimos segmentos se vuelven a intercalar, dando como resultado ambos descendientes mostrados en la figura. El proceso se repite hasta cruzar a toda la población actual, y obteniendo como resultado la generación de una nueva población.




FIGURA 5.2: Cruce de 2 reproductores.

5.1.6. Mutación

El procedimiento de mutación se aplica después del cruzamiento en cada individuo independientemente, en el paso 6 del Algoritmo 2. Específicamente, para el individuo seleccionado, según la probabilidad de mutación obtenida, se elige aleatoriamente una posición del vector para cambiar la ruta utilizada en dicha posición. Seleccionando una ruta de las disponibles para dicha posición, se tiene una probabilidad más alta de generar una solución factible. La probabilidad de mutación utilizada fue del 2 %.

5.1.7. Asignación de Espectro

Básicamente, un algoritmo de Asignación de Espectro (SA, *Spectrum Assignment*) se aplica a cada i -ésimo gen de forma consecutiva en el orden pre establecido por los índices en el cromosoma.

El algoritmo SA utilizado en el MOGA es el First Fit [WCP11], el cual asigna el primer FS libre encontrado y que cumpla las restricciones del problema. De esta manera se asegura que, los nuevos individuos obtenidos satisfacen las restricciones y la nueva población está compuesta de soluciones factibles.

Como las operaciones de cruce y mutación se realizan únicamente para la asignación de rutas, estas operaciones podrían generar soluciones no factibles en cuanto a FS asignados, es decir, los individuos resultantes de dichas operaciones podrían no satisfacer las restricciones del problema. Es por ello que, luego de las operaciones de generación de

individuos, se vuelven a realizar el cálculo de asignación de espectro para cada individuo generado, como se observa en el paso 7 del Algoritmo 2

5.1.8. Reemplazo

Los individuos nuevos reemplazan a individuos viejos si sus valores de fitness son mejores que los de los viejos. El tamaño de la población en cada generación se mantiene fijo.

Para realizar la selección de los mejores individuos, se necesitan evaluar los individuos de la nueva población, como describe el Algoritmo 2 en el paso 8.

Las soluciones generadas por las operaciones de cruce y mutación se agregan a la nueva población. Luego, se seleccionan los mejores individuos de la población actual y la nueva, paso 9 Algoritmo 2, es decir aquellos con menor fitness, y los demás son eliminados por no considerarse aptos para la siguiente generación. Por lo tanto, el algoritmo comienza todo de nuevo, desde la elección de los reproductores, hasta que se alcanza la condición de parada.

5.1.9. Criterio de Parada

En esta implementación se utilizó un tiempo máximo de ejecución como criterio de parada.

Parte III

Pruebas experimentales y resultados

Capítulo 6

Pruebas experimentales y resultados

En esta sección se presentan y se analizan los resultados de las pruebas experimentales.

Las pruebas realizadas considerando distintos tipos de carga de tráfico, distintas topologías, distintos valores de K y distintas cantidades demandadas, intentan replicar diversos escenarios posibles del problema a resolver. Los escenarios más simples ayudan a verificar la calidad de los algoritmos propuestos pudiendo realizarse comparaciones con análisis manuales. Los escenarios de mayor complejidad, buscan replicar situaciones reales de demandas de tráfico. Las pruebas experimentales realizadas, demuestran que todos estos escenarios pueden ser resueltos con al menos uno de los algoritmos propuestos, obteniendo resultados promisorios.

6.1. Ambiente de pruebas

Los experimentos fueron realizados en una computadora con procesador Intel Core i7 (2.40 GHz.) y 8 GB de memoria RAM. El motor utilizado para la implementación y ejecución del MOILP fue el IBM ILOG CPLEX Optimization Studio Version 12.6, y la implementación y ejecución del MOGA y del GA [CR13] fueron realizados con JAVA 8.

Todas las ejecuciones realizadas fueron ejecutadas con 3 topologías de red direccionales: una red de 6 nodos, la topología NSF de 14 nodos y la topología Arpa-2 de 21 nodos las

cuales se pueden observar en las Figuras 6.1, 6.2 y 6.3 [Ass+14]. Se ha considerado sin límite al número de FS en los enlaces ópticos dado que el problema es del tipo corresponsio estático correspondiendo a una planificación.




FIGURA 6.1: Topología de red de 6 nodos.




FIGURA 6.2: Topología de red NSF de 14 nodos con distancia en kilómetros.




FIGURA 6.3: Topología de red Arpa-2 de 21 nodos.

Las cargas de tráfico utilizadas fueron del tipo all-to-all, es decir, cada nodo de la red realiza una solicitud de transferencia a todos los demás nodos de la red. Además, dichas

cargas de tráfico fueron divididas en dos tipos: carga de tráfico uniforme y carga de tráfico aleatoria. En la primera, todas las demandas solicitan igual cantidad de FS, las cantidades solicitadas fueron: 50, 100, 150 y 200 FS. Para las cargas aleatorias, se dividieron también en 4 categorías pero se utilizaron dichas cantidades como cantidad máxima, es decir, para la categoría de 50 FS, para cada demanda se generó un valor aleatorio entre 1 y 50 como cantidad solicitada de FS; para la categoría de 100, para cada demanda se generó un valor aleatorio entre 1 y 100 como cantidad solicitada de FS; para la categoría de 150, para cada demanda se generó un valor aleatorio entre 1 y 150 como cantidad solicitada de FS; y finalmente para la categoría de 200 para cada demanda se generó un valor aleatorio entre 1 y 200 como cantidad solicitada de FS.

Otra variante que se tuvo en cuenta para la ejecución de las pruebas fue la cantidad de rutas más cortas precalculadas, es decir, el valor de k . Las ejecuciones del MOGA y del GA [CR13] fueron hechas con los siguientes valores de $k = 1, 2, 3, 4, 5, 6$ y 7 , excepto para la topología de 6 nodos ya que en esta topología existen hasta 3 caminos para cada par de nodos. El MOILP se ejecutó con los siguientes valores de k : para la topología de 6 nodos se utilizó $k = 1, 2$ y 3 con un tiempo límite de 2 horas; para la topología NSF se definió un tiempo límite de 4 horas y se obtuvieron resultados con $k = 1, 2, 3, 4$ y 5 , excepto para los escenarios de demandas de 200 FS en los cuales solo se obtuvieron resultados hasta $k = 4$; y para la topología ARPA-2 también se definió un tiempo límite de 4 horas y se obtuvieron resultados solo para $k = 1$. La limitación en las ejecuciones del MOILP, vienen dadas por el tamaño de las topologías, ya que las implementaciones ILP no son generalmente escalables.

Para las ejecuciones del MOGA, fueron utilizados los valores mostrados en la Tabla 6.1 como parámetros evolutivos.

Como el MOGA y el GA son algoritmos estocásticos, cada ejecución realizada puede presentar resultados distintos. Teniendo en cuenta ese factor, con el MOGA se realizaron varias ejecuciones por cada escenario planteado. La cantidad de ejecuciones por escenario es definido por el parámetro *Cantidad de corridas independientes* de la Tabla 6.1.

Los resultados finales del MOGA son los valores promedio obtenidos de todas las ejecuciones de cada escenario, es decir, de 30 corridas independientes realizadas para un escenario, se promediaron los valores de las funciones objetivo y dichos valores son los presentados en los resultados.

TABLA 6.1: Parámetros utilizados para la ejecución del MOGA.

Parámetro	Valor
Tamaño de la población	100
Probabilidad de mutación	2 %
Criterio de parada	5 minutos de ejecución
Cantidad de corridas independientes	30

En la Tabla 6.2, podemos observar un resumen de los escenarios ejecutados. Se muestran las topologías utilizadas, los valores de K para cada topología, las cargas de tráfico (que fueron divididas en carga uniforme y carga aleatoria), y el tiempo de ejecución que, en el caso del MOILP, representan el tiempo límite de ejecución definido, y en el caso del MOGA, representan el tiempo total de ejecución, ya que para cada ejecución independiente se definieron 5 minutos como criterio de parada y para cada escenario se realizaron 30 ejecuciones.

Básicamente, dado un escenario consistente en una topología, una cantidad de rutas y carga de tráfico, se procede a:

1. Calcular una solución MOILP
2. Calcular 30 soluciones MOGA
3. Calcular valores promedio de las 30 soluciones MOGA de las funciones objetivo y Fitness
4. Calcular 30 soluciones GA
5. Calcular valores promedio de las 30 soluciones GA de las funciones objetivo y Fitness
6. Realizar análisis de las soluciones

Basados en estos pasos, se presentan los siguientes resultados experimentales.

6.2. Resultados de Carga Uniforme: MOILP vs MOGA

En esta sección se analizan todos los resultados de las funciones objetivo y del fitness, del MOILP y del MOGA. Los resultados son expuestos en el Apéndice A.

TABLA 6.2: Escenarios de ejecuciones.

Topología	K	Carga	Tiempo
6-nodos	1, 2, 3	Uniforme 50, 100, 150, 200 Aleatoria: 1-50, 1-100, 1-150, 1-200	MOILP: 2 horas, MOGA: 5:30 = 150 minutos
NSF	1, 2, 3, 4, 5, 6	Uniforme 50, 100, 150, 200 Aleatoria: 1-50, 1-100, 1-150, 1-200	MOILP: 4 horas, MOGA: 5:30 = 150 minutos
ARPA-2	1, 2, 3, 4, 5, 6	Uniforme 50, 100, 150, 200 Aleatoria: 1-50, 1-100, 1-150, 1-200	MOILP: 4 horas, MOGA: 5:30 = 150 minutos

Las Figuras [A.1](#) [A.3](#) [A.5](#) y [A.7](#) muestran los valores obtenidos por el MOILP de Fitness, máximo FS, distancia total y costo total, respectivamente, para la topología de 6 nodos. El valor mostrado en el eje vertical es el valor de la función objetivo, y se obtuvieron resultados hasta $k = 3$, ya que con una topología de 6 nodos no existen más de 3 posibles caminos para cada par de nodos. Al analizar la Figura [A.1](#) se puede observar que al tener 2 posibles caminos el valor del fitness mejora, es decir, con $k = 2$ se obtuvo una gran mejora comparado con $k = 1$.

Se puede observar, que al tener dos posibles rutas para satisfacer las demandas, se utilizó una segunda ruta en alguna o varias demandas, lo que aumentó el valor de la distancia total recorrida como se observa en la Figura [A.5](#), ya que la primera ruta es la más corta. Pero utilizar una ruta más larga produjo una mejor utilización del espectro disponible, ya que para $k = 2$, en la Figura [A.3](#) se observa una disminución en el máximo FS utilizado.

Otra observación que se puede realizar sobre estos resultados, es que, la mayor mejora se obtuvo de $k = 1$ a $k = 2$, ya que con $k = 3$ prácticamente se mantiene el valor del fitness.

Con los resultados mencionados anteriormente, se valida la implementación MOILP propuesta. El mismo comportamiento se observa para la topología NSF-14 en las Figuras [A.9](#) [A.11](#) [A.13](#) y [A.15](#), obteniendo resultados hasta $k = 5$ excepto para la carga de 200 FS que solo se pudo calcular soluciones con hasta $k = 4$. Para la topología ARPA-2 solo se se pudo calcular soluciones con $k = 1$.

Las Figuras [A.2](#) [A.4](#) [A.6](#) y [A.8](#) muestran los valores de fitness, distancia total, máximo FS y costo total, respectivamente, obtenidos por el MOGA para la topología de 6 nodos. Se puede observar que consigue obtener prácticamente los mismos resultados que el MOILP con valores cercanos al óptimo.

Los resultados obtenidos por el MOGA para el fitness y las funciones objetivo de la topología NSF-14, se muestran en las Figuras A.10 A.12 A.14 y A.16. Se puede observar también que la mejora más significativa se produce con $k = 2$, a partir de $k = 3$ casi no se ven variaciones en los resultados y va convergiendo.

Finalmente, las Figuras A.17 A.20 A.22 y A.24 muestran los valores de fitness y de las funciones objetivos para la topología ARPA-2 obtenidos por el MOGA. Al observar los valores de fitness obtenidos por ambas implementaciones, se puede verificar que para todos los valores de k en las 3 topologías, el MOILP superó los resultados obtenidos por el MOGA, sin embargo, el MOGA presenta resultados muy cercanos al óptimo generando soluciones promisorias.

6.3. Resultados de Carga Aleatoria: MOILP vs MOGA

Para estos escenarios, se presentan los valores de fitness de las 3 topologías, los obtenidos por el MOILP se muestran en las Figuras B.1 B.9 y B.17, y los obtenidos por el MOGA se muestran en las Figuras B.2 B.10 y B.18. Se puede observar que ambas implementaciones presentan un comportamiento similar al que tienen con carga de tráfico uniforme, es decir, los mejores valores obtenidos de fitness son con valores de $k = 2$. Además, el MOILP genera todos los resultados solo para la topología de 6 nodos por ser una red pequeña, para las topologías NSF y ARPA solo produjo resultados en algunos escenarios, mientras que el MOGA puede obtener resultados en las 3 topologías, con resultados cercanos al óptimo.

Al observar los valores de fitness obtenidos para la topología ARPA-2, por el MOILP en la Figura B.17 y por el MOGA en la Figura B.18, se puede verificar que para $k = 1$, el MOGA consiguió obtener el mismo resultado que el MOILP, es decir, el valor óptimo. Esto indica que el MOGA genera soluciones promisorias.

6.4. Resultados de Carga Uniforme: GA del estado del arte vs MOGA Propuesto

El trabajo del estado del arte presentado en [CR13], propone un GA para la resolución del problema RSA. Dicho trabajo, utiliza como función objetivo la minimización del costo total, en comparación al MOGA propuesto que minimiza 3 funciones objetivo simultáneamente, mencionados en la sección 4.2. Igualmente, se modificó el GA agregando las 3 funciones objetivo para calcular el fitness, de esa manera fue posible comparar los resultados de ambas implementaciones.

Otra diferencia entre ambos trabajos es el proceso de asignación de espectro, en el GA se propone utilizar el método First-Fit para asignación de espectro solo con el 30 % de las demandas y utiliza el método Random Fit para el 70 % restante, mientras que el MOGA utiliza First-Fit para atender todas las demandas recibidas.

Los operadores genéticos del GA también presentan diferencias con los del MOGA. Para el GA, se utiliza el operador cruce de un solo punto, mientras que en el MOGA se utiliza el de dos puntos. Además, el porcentaje de mutación utilizados en ambas implementaciones también es distinto. Los parámetros utilizados para la implementación del GA son presentados en la Tabla 6.3 y fueron extraídos de [CR13], y los parámetros utilizados para el MOGA son presentados en la Tabla 6.1.

Podemos empezar analizando el comportamiento de ambas implementaciones con la topología más pequeña, la de 6 nodos. A partir de los resultados de fitness presentados en las Figuras C.2 y C.1, se observa una mejora constante con el aumento del valor de k , pero ya desde $k = 1$ ambas implementaciones presentan resultados ligeramente distantes uno de otro. El GA inicia con un valor cercano al límite superior, 3, es decir, al peor valor. Se obtiene una gran mejora con $k = 2$, pero dicho valor casi es igual al peor valor obtenido por el MOGA, alcanzando 2. Con $k = 3$ el MOGA obtiene un valor menor a 1, siendo este su mejor resultado, y no pudiendo ser alcanzado por el GA.

Analizando las Figuras C.10, C.9, C.18 y C.17, también se observa el mismo comportamiento para ambas implementaciones, con una mejora significativa del MOGA propuesto sobre el GA base utilizado.

TABLA 6.3: Parámetros utilizados para la ejecución del GA.

Parámetro	Valor
Tamaño de la población	100
Probabilidad de mutación	3 %
Criterio de parada	5 minutos de ejecución
Cantidad de corridas independientes	30

6.5. Resultados de Carga Aleatoria: GA del estado del arte vs MOGA Propuesto

Observando las Figuras presentadas en el Apéndice D, resultado de las ejecuciones realizadas en los escenarios de carga aleatoria del GA y del MOGA, podemos concluir que ambas implementaciones mantienen un comportamiento constante, es decir, similar en todos los escenarios planteados, pero con una diferencia resaltante en cuanto a calidad de resultados.

En las Figuras D.2 y D.1 se presentan los resultados de fitness obtenidos para la topología de 6 nodos con el MOGA y el GA respectivamente. Para la topología NSF-14 se pueden observar los valores de fitness obtenidos por el MOGA en la Figura D.10 y los valores de fitness obtenidos por el GA en la Figura D.9. Por último en la Figura D.18 podemos observar el fitness obtenido por el MOGA y en la Figura D.17 el obtenido por el GA.

Los mejores valores de fitness obtenidos por el GA, son ampliamente superados por los mejores valores de fitness obtenidos por el MOGA. Esto se puede evidenciar con las figuras mencionadas arriba.

En general, las diferencias obtenidas por ambas implementaciones, indican la notable mejora del MOGA sobre el GA, para todos los valores de k utilizados y para las distintas cargas de tráfico.

6.6. Breve Resumen

Finalmente, en la Tabla 6.4 podemos ver un resumen comparativo de las soluciones logradas por los algoritmos presentados. Dicha tabla, está basada en los escenarios que utilizan carga de tráfico aleatoria y se presentan resultados sobre las 3 topologías utilizadas.

En la primera columna se indica la topología y en la segunda el número de rutas. En la tercera columna se observa el promedio del fitness logrado por el MOILP considerando las cargas aleatorias $c \in \{1 - 50, 1 - 100, 1 - 150, 1 - 200\}$, número de ruta $k \in K$ y topología $t \in \{6\text{ nodos}, NSF, ARPA\}$, dado por:

$$F_{MOILP}^{k,t} = \frac{1}{4} \cdot \sum_c F_{MOILP}^{c,k,t} \quad (6.1)$$

En la cuarta columna se observa la tasa relativa promedio del fitness obtenido por el MOGA frente al obtenido por el MOILP, calculado como:

$$F_{MOGA-MOILP}^{k,t} = \frac{1}{4} \cdot \sum_c \left(\frac{F_{MOGA}^{c,k,t} - F_{MOILP}^{c,k,t}}{F_{MOGA}^{c,k,t}} \right) \quad (6.2)$$

Similar a la cuarta columna, en la quinta se presentan resultados comparativos entre el MOGA y el GA con:

$$F_{AG-MOGA}^{k,t} = \frac{1}{4} \cdot \sum_c \left(\frac{F_{GA}^{c,k,t} - F_{MOGA}^{c,k,t}}{F_{GA}^{c,k,t}} \right) \quad (6.3)$$

Observando los resultados en general, el MOGA logra resultados muy prometedores con tasas relativas bajas. Esto indica que el MOGA logra soluciones cercanamente buenas al modelo MOILP considerando los parámetros de optimización dados en las Tablas 6.1 y 6.2. Sin embargo, para la topología 6 nodos con $k = 2$ el desempeño promedio del MOGA no fue el esperado. Por otra parte, el MOGA demuestra tener un desempeño superior al propuesto en la literatura, ver columna 5 de la Tabla 6.4. La alta tasa relativa indica que las soluciones GA son pobres frente a las obtenidas por el MOGA, lo que indica que la elección de los operadores genéticos del MOGA son más apropiados que los del GA.

Observando las Figuras de las funciones objetivo de los Apéndices, se visualiza el impacto del número de rutas K :

TABLA 6.4: Mejoras obtenidas (%), MOILP vs. MOGA, MOGA vs. GA.

Topología	K	MOILP	MOILP vs. MOGA	MOGA vs. GA
6 nodos	1	1,528	0,02 %	37,16 %
	2	0,90074	15,92 %	40,74 %
	3	0,90074	6,62 %	34,57 %
NSF	1	1,528	0,05 %	38,69 %
	2	1,001	0,09 %	48,86 %
	3	0,810	0,22 %	54,20 %
	4	0,705	0,25 %	57,45 %
	5	-	-	59,59 %
	6	-	-	61,34 %
ARPA	1	1,54720	0,00 %	46,57 %
	2	-	-	49,52 %
	3	-	-	54,08 %
	4	-	-	56,62 %
	5	-	-	58,59 %
	6	-	-	60,22 %

- si K aumenta, el fitness mejora hasta un valor mínimo,
- si K aumenta, el costo y la distancia total empeoran levemente,
- si K aumenta, el espectro utilizado se reduce notablemente,
- a mayor tamaño de la topología, el impacto de K es más importante,
- el valor del espectro normalizado mejora más que el empeoramiento de costo y distancia normalizados combinados cuando aumenta K .

Capítulo 7

Conclusiones

7.1. Conclusiones generales

En este trabajo se abarcó en gran medida el estudio de las capacidades actuales de transporte de datos a través del medio fibra óptica y de las técnicas más ampliamente investigadas y estudiadas para optimizar los recursos.

Como ya se había mencionado en el capítulo 1, la tecnología emergente para mejorar los servicios proveídos de manera eficiente es la grilla de rejilla flexible o flexigrid. Esta tecnología introduce el problema RSA y una serie de complejidades que deben ser abordadas. Varias propuestas de solución del estado del arte actual fueron investigadas y analizadas, de las cuales pudimos concluir que el RSA aún tiene varias arista que considerar. De allí nació la idea de modelar el problema RSA como un MOP, teniendo en cuenta las funciones objetivo de: máximo FS utilizado, distancia total recorrida y costo total. La propuesta realizada fue el diseño de una solución exacta basada en un modelo ILP y una heurística basada en un GA, ambos multi-objetivos, dentro de un ambiente off-line de demandas punto-a-punto.

Por otra parte, el trabajo presenta un análisis de cantidad de rutas disponibles y el impacto de ello en la calidad de las soluciones, en todos los escenarios utilizados.

Además, se replicó el trabajo estudiado del estado del arte, en el cual se propone un GA mono-objetivo. Dicho GA fue modificado para poder comparar con la propuesta bajo las mismas métricas. Los resultados fueron bastante favorables para nuestra propuesta,

ya que en todos los escenarios planteados se pueden observar mejoras en los valores obtenidos, tanto del fitness como de las demás funciones objetivo.

Los resultados obtenidos por el MOILP y el MOGA propuestos, validan la calidad de ambas implementaciones, ya que el ILP sirve para obtener los valores óptimos en redes pequeñas y para esas mismas redes el MOGA ofrece un resultado muy cercano al óptimo.

Por otra parte, los resultados indican que el MOGA es más competitivo que el GA propuesto en la literatura.

7.2. Trabajos futuros

En función de las conclusiones obtenidas y con el objetivo de futuras mejoras, se presenta a continuación una serie de propuestas que podrían dar continuidad a este trabajo:

- Analizar otras estructuras cromosómicas que representen una solución y otros enfoques de cruce y mutación.
- Aplicar un enfoque multi-objetivo considerando el concepto Pareto para la resolución del MOGA.
- Utilizar otros métodos para la resolución de ruteo, distintos al utilizado en este trabajo que fue la implementación con K-shortest path y first fit.
- Utilizar otros métodos para la resolución de la asignación de espectro, distintos al utilizado en este trabajo que fue el First Fit con un orden definido de atención de demandas.
- Considerar el problema de la secuencia óptima de solicitudes en soluciones de RSA simples.
- Abordar el problema de la asignación de modulación y multi-path .

Apéndice A

Carga Uniforme: MOILP vs. MOGA

A continuación se muestran los resultados obtenidos por las implementaciones propuestas, MOILP y MOGA, para los escenarios con carga uniforme, para las 3 topologías utilizadas.

Los valores mostrados a continuación son:

- Fitness
- Máximo FS utilizado en la red
- La distancia total recorrida
- El costo total obtenido.

Para el MOGA corresponde a valores promedio de 30 corridas independientes.

A.1. Topología: 6 nodos




FIGURA A.1: Fitness obtenido por el MOILP para la topología de 6 nodos con carga uniforme.




FIGURA A.2: Fitness promedio obtenido por el MOGA para la topología de 6 nodos con carga uniforme.




FIGURA A.4: Máximo FS promedio obtenido por el MOGA para la topología de 6 nodos con carga uniforme.

FIGURA A.3: Máximo FS obtenido por el MOILP para la topología de 6 nodos con carga uniforme.




FIGURA A.6: Distancia total promedio obtenida por el MOGA para la topología de 6 nodos con carga uniforme.

FIGURA A.5: Distancia total obtenida por el MOILP para la topología de 6 nodos con carga uniforme.




FIGURA A.8: Costo total promedio obtenido por el MOGA para la topología de 6 nodos con carga uniforme.

FIGURA A.7: Costo total obtenido por el MOILP para la topología de 6 nodos con carga uniforme.

Debido a la poca clarificación en la Figura A.4 de los resultados de Máximo FS obtenidos por el MOGA, a continuación se presentan los resultados numéricos en la Tabla A.1.

TABLA A.1: Máximo FS promedio obtenido por el MOGA para la topología 6 nodos con carga uniforme.

<div>FS</div> <div>K</div>	50	100	150	200
1	305,000	605,000	905,000	1205,000
2	303,000	603,000	903,000	1203,000
3	301,000	601,000	901,000	1201,000

A.2. Topología: NSF-14




FIGURA A.10: Fitness promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.

FIGURA A.9: Fitness obtenido por el MOILP para la topología NSF-14 con carga uniforme.




FIGURA A.12: Máximo FS promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.

FIGURA A.11: Máximo FS obtenido por el MOILP para la topología NSF-14 con carga uniforme.




FIGURA A.14: Distancia total promedio obtenida por el MOGA para la topología NSF-14 con carga uniforme.

FIGURA A.13: Distancia total obtenida por el MOILP para la topología NSF-14 con carga uniforme.




FIGURA A.16: Costo total promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.

FIGURA A.15: Costo total obtenido por el MOILP para la topología NSF-14 con carga uniforme.

Debido a la poca clarificación en la Figura A.12 de los resultados de Máximo FS obtenidos por el MOGA, a continuación se presentan los resultados numéricos en la Tabla A.2.

TABLA A.2: Máximo FS promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.

K \ FS	50	100	150	200
1	2.090,000	4.140,000	6.167,000	8.037,000
2	1.886,000	3.736,000	5.737,000	7.335,000
3	1.861,000	3.736,000	5.485,000	7.335,000
4	1.873,000	3.635,000	5.460,000	7.305,000
5	1.852,000	3.635,000	5.435,000	7.235,000
6	1.835,000	3.635,000	5.435,000	7.235,000

A.3. Topología: ARPA-2




FIGURA A.18: Fitness promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.

FIGURA A.17: Fitness obtenido por el MOILP para la topología ARPA-2 con carga uniforme.




FIGURA A.20: Máximo FS promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.

FIGURA A.19: Máximo FS obtenido por el MOILP para la topología ARPA-2 con carga uniforme.




FIGURA A.22: Distancia total promedio obtenida por el MOGA para la topología ARPA-2 con carga uniforme.

FIGURA A.21: Distancia total obtenida por el MOILP para la topología ARPA-2 con carga uniforme.




FIGURA A.24: Costo total promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.

FIGURA A.23: Costo total obtenido por el MOILP para la topología ARPA-2 con carga uniforme.

Debido a la poca clarificación en la Figura A.20 de los resultados de Máximo FS obtenidos por el MOGA, a continuación se presentan los resultados numéricos en la Tabla A.3.

TABLA A.3: Máximo FS promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.

K \ FS	50	100	150	200
1	3.518,000	6.463,000	9.663,000	13.466,000
2	2.447,000	4.847,000	7.398,000	9.848,000
3	2.396,000	4.948,000	7.096,000	9.647,000
4	2.396,000	4.746,000	7.096,000	9.647,000
5	2.396,000	4.948,000	7.247,000	9.647,000
6	2.447,000	4.948,000	7.096,000	9.647,000

Apéndice B

Carga Aleatoria: MOILP vs. MOGA

A continuación se muestran los resultados obtenidos por las implementaciones propuestas, MOILP y MOGA, para los escenarios con carga aleatoria, para las 3 topologías utilizadas.

Los valores mostrados a continuación son:

- Fitness
- Máximo FS utilizado en la red
- La distancia total recorrida
- El costo total obtenido.

Para el MOGA corresponde a valores promedio de 30 corridas independientes.

B.1. Topología: 6 nodos




FIGURA B.1: Fitness obtenido por el MOILP para la topología de 6 nodos con carga aleatoria.




FIGURA B.2: Fitness promedio obtenido por el MOGA para la topología de 6 nodos con carga aleatoria.




FIGURA B.3: Máximo FS obtenido por el MOILP para la topología de 6 nodos con carga aleatoria.




FIGURA B.4: Máximo FS promedio obtenido por el MOGA para la topología de 6 nodos con carga aleatoria.




FIGURA B.5: Distancia total obtenida por el MOILP para la topología de 6 nodos con carga aleatoria.




FIGURA B.6: Distancia total promedio obtenida por el MOGA para la topología de 6 nodos con carga aleatoria.




FIGURA B.8: Costo total promedio obtenido por el MOGA para la topología de 6 nodos con carga aleatoria.

FIGURA B.7: Costo total obtenido por el MOILP para la topología de 6 nodos con carga aleatoria.

Debido a la poca clarificación en la Figura B.4 de los resultados de Máximo FS obtenidos por el MOGA, a continuación se presentan los resultados numéricos en la Tabla B.1.

TABLA B.1: Máximo FS promedio obtenido por el MOGA para la topología 6 nodos con carga aleatoria.

<div>FS</div> <div>K</div>	50	100	150	200
1	172,000	380,000	514,000	732,000
2	172,000	411,000	524,000	766,000
3	187,000	375,000	482,000	924,000

B.2. Topología: NSF-14

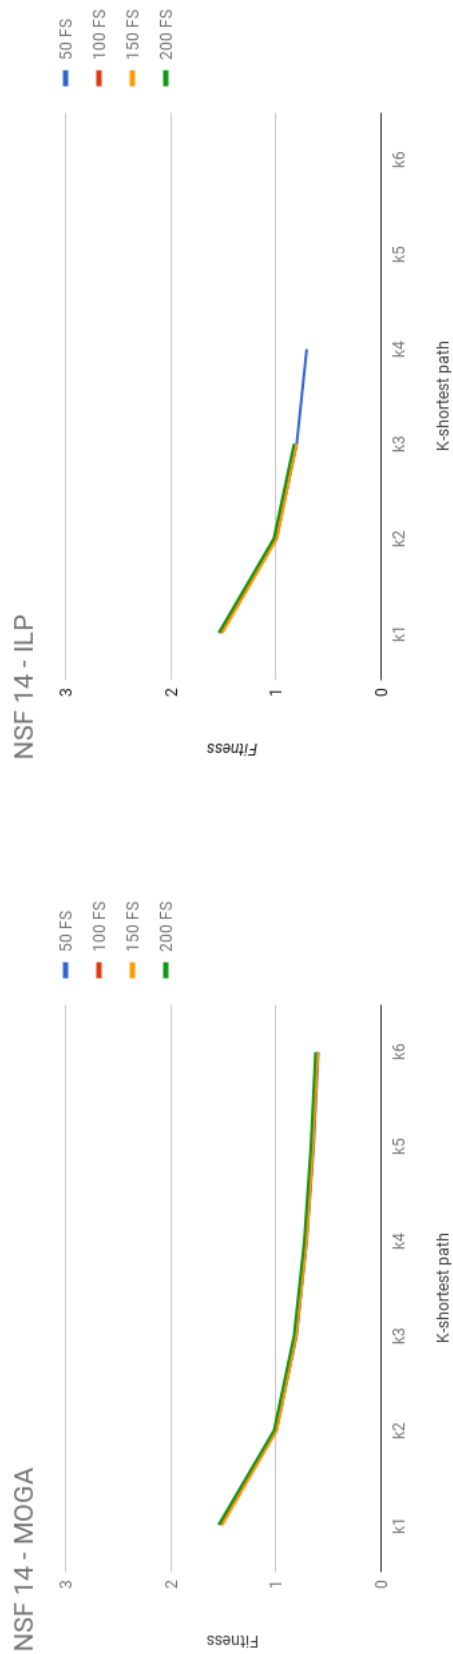


FIGURA B.10: Fitness promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.

FIGURA B.9: Fitness obtenido por el MOILP para la topología NSF-14 con carga aleatoria.




FIGURA B.12: Máximo FS promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.

FIGURA B.11: Máximo FS obtenido por el MOILP para la topología NSF-14 con carga aleatoria.




FIGURA B.14: Distancia total promedio obtenida por el MOGA para la topología NSF-14 con carga aleatoria.

FIGURA B.13: Distancia total obtenida por el MOILP para la topología NSF-14 con carga aleatoria.




FIGURA B.16: Costo total promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.

FIGURA B.15: Costo total obtenido por el MOILP para la topología NSF-14 con carga aleatoria.

Debido a la poca clarificación en la Figura B.12 de los resultados de Máximo FS obtenidos por el MOGA, a continuación se presentan los resultados numéricos en la Tabla B.2.

TABLA B.2: Máximo FS promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.

K \ FS	50	100	150	200
1	1.018,000	1.964,000	2.939,000	4.355,000
2	996,000	1.961,000	2.936,000	4.269,000
3	990,000	1.958,000	2.879,000	4.225,000
4	983,000	1.931,000	2.859,000	4.146,000
5	982,000	1.910,000	2.854,000	4.140,000
6	979,000	1.908,000	2.841,000	4.138,000

B.3. Topología: ARPA-2




FIGURA B.18: Fitness promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.

FIGURA B.17: Fitness obtenido por el MOILP para la topología ARPA-2 con carga aleatoria.




FIGURA B.20: Máximo FS promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.

FIGURA B.19: Máximo FS obtenido por el MOILP para la topología ARPA-2 con carga aleatoria.




FIGURA B.22: Distancia total promedio obtenida por el MOGA para la topología ARPA-2 con carga aleatoria.

FIGURA B.21: Distancia total obtenida por el MOILP para la topología ARPA-2 con carga aleatoria.




FIGURA B.24: Costo total promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.

FIGURA B.23: Costo total obtenido por el MOILP para la topología ARPA-2 con carga aleatoria.

Debido a la poca clarificación en la Figura B.20 de los resultados de Máximo FS obtenidos por el MOGA, a continuación se presentan los resultados numéricos en la Tabla B.3.

TABLA B.3: Máximo FS promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.

K \ FS	50	100	150	200
1	2.034,000	3.676,000	6.037,000	7.506,000
2	1.270,000	2.830,000	3.913,000	5.733,000
3	1.309,000	2.893,000	3.917,000	5.813,000
4	1.330,000	2.881,000	3.965,000	6.065,000
5	1.376,000	2.899,000	4.042,000	6.091,000
6	1.302,000	2.891,000	4.140,000	6.021,000

Apéndice C

Carga Uniforme: GA del estado del arte vs. MOGA propuesto

A continuación se muestran los resultados obtenidos por la implementación del GA base estudiado y del MOGA propuesto, para los escenarios con carga uniforme, para las 3 topologías utilizadas.

Los valores mostrados a continuación son:

- Fitness
- Máximo FS utilizado en la red
- La distancia total recorrida
- El costo total obtenido.

Para ambos, MOGA y GA, corresponde a valores promedio de 30 corridas independientes.

C.1. Topología: 6 nodos




FIGURA C.1: Fitness promedio obtenido por el GA para la topología de 6 nodos con carga uniforme.




FIGURA C.2: Fitness promedio obtenido por el MOGA para la topología de 6 nodos con carga uniforme.




FIGURA C.3: Máximo FS promedio obtenido por el GA para la topología de 6 nodos con carga uniforme.




FIGURA C.4: Máximo FS promedio obtenido por el MOGA para la topología de 6 nodos con carga uniforme.




FIGURA C.6: Distancia total promedio obtenida por el MOGA para la topología de 6 nodos con carga uniforme.

FIGURA C.5: Distancia total promedio obtenida por el GA para la topología de 6 nodos con carga uniforme.




FIGURA C.7: Costo total promedio obtenido por el GA para la topología de 6 nodos con carga uniforme.




FIGURA C.8: Costo total promedio obtenido por el MOGA para la topología de 6 nodos con carga uniforme.

C.2. Topología: NSF-14

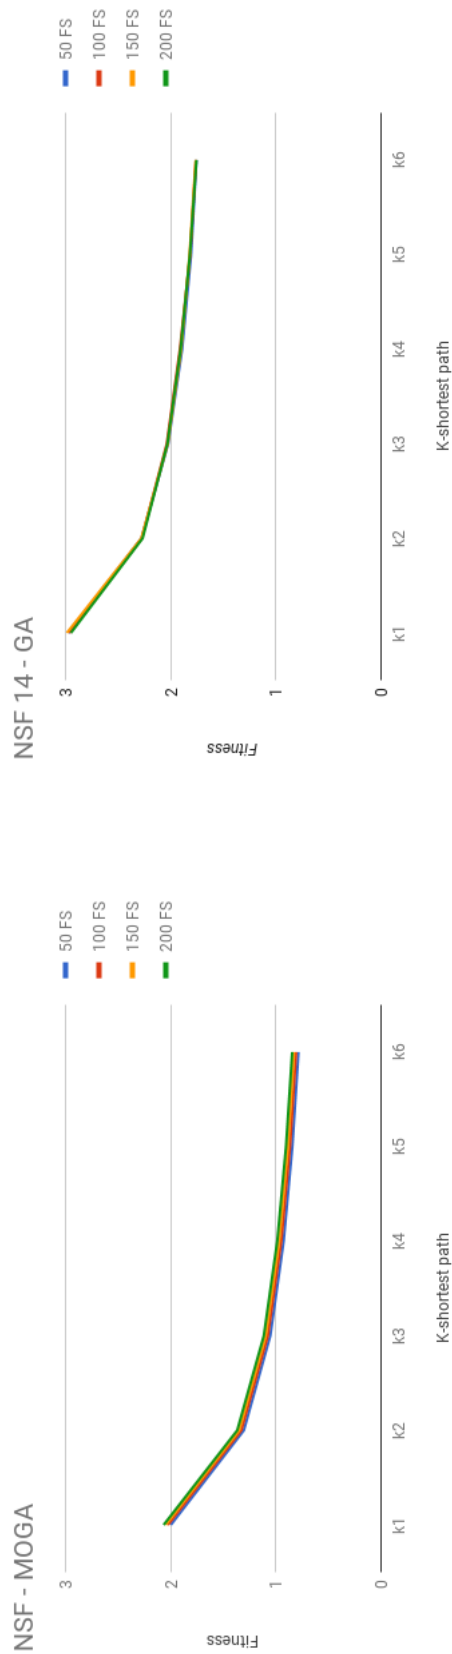


FIGURA C.10: Fitness promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.

FIGURA C.9: Fitness promedio obtenido por el GA para la topología NSF-14 con carga uniforme.




FIGURA C.12: Máximo FS promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.

FIGURA C.11: Máximo FS promedio obtenido por el GA para la topología NSF-14 con carga uniforme.




FIGURA C.14: Distancia total promedio obtenida por el MOGA para la topología NSF-14 con carga uniforme.

FIGURA C.13: Distancia total promedio obtenida por el GA para la topología NSF-14 con carga uniforme.




FIGURA C.15: Costo total promedio obtenido por el GA para la topología NSF-14 con carga uniforme.




FIGURA C.16: Costo total promedio obtenido por el MOGA para la topología NSF-14 con carga uniforme.

C.3. Topología: ARPA-2




FIGURA C.18: Fitness promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.

FIGURA C.17: Fitness promedio obtenido por el GA para la topología ARPA-2 con carga uniforme.




FIGURA C.20: Máximo FS promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.

FIGURA C.19: Máximo FS promedio obtenido por el GA para la topología ARPA-2 con carga uniforme.




FIGURA C.22: Distancia total promedio obtenida por el MOGA para la topología ARPA-2 con carga uniforme.

FIGURA C.21: Distancia total promedio obtenida por el GA para la topología ARPA-2 con carga uniforme.




FIGURA C.23: Costo total promedio obtenido por el GA para la topología ARPA-2 con carga uniforme.




FIGURA C.24: Costo total promedio obtenido por el MOGA para la topología ARPA-2 con carga uniforme.

Apéndice D

Carga Aleatoria: GA del estado del arte vs. MOGA propuesto

A continuación se muestran los resultados obtenidos por la implementación del GA base estudiado y del MOGA propuesto, para los escenarios con carga aleatoria, para las 3 topologías utilizadas.

Los valores mostrados a continuación son:

- Fitness
- Máximo FS utilizado en la red
- La distancia total recorrida
- El costo total obtenido.

Para ambos, MOGA y GA, corresponde a valores promedio de 30 corridas independientes.

D.1. Topología: 6 nodos




FIGURA D.1: Fitness promedio obtenido por el GA para la topología de 6 nodos con carga aleatoria.




FIGURA D.2: Fitness promedio obtenido por el MOGA para la topología de 6 nodos con carga aleatoria.




FIGURA D.3: Máximo FS promedio obtenido por el GA para la topología de 6 nodos con carga aleatoria.




FIGURA D.4: Máximo FS promedio obtenido por el MOGA para la topología de 6 nodos con carga aleatoria.




FIGURA D.5: Distancia total promedio obtenida por el GA para la topología de 6 nodos con carga aleatoria.




FIGURA D.6: Distancia total promedio obtenida por el MOGA para la topología de 6 nodos con carga aleatoria.




FIGURA D.7: Costo total promedio obtenido por el GA para la topología de 6 nodos con carga aleatoria.




FIGURA D.8: Costo total promedio obtenido por el MOGA para la topología de 6 nodos con carga aleatoria.

D.2. Topología: NSF-14

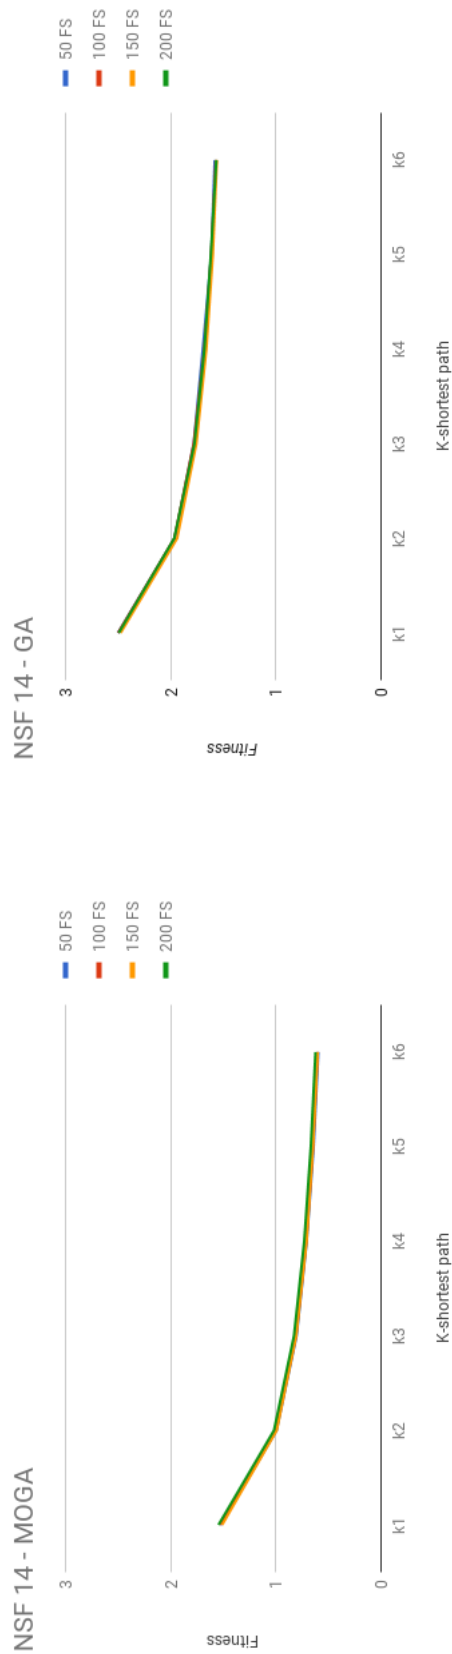


FIGURA D.10: Fitness promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.

FIGURA D.9: Fitness promedio obtenido por el GA para la topología NSF-14 con carga aleatoria.




FIGURA D.12: Máximo FS promedio obtenido por el MOGA para la topología NSF-14 con carga aleatoria.

FIGURA D.11: Máximo FS promedio obtenido por el GA para la topología NSF-14 con carga aleatoria.




FIGURA D.14: Distancia total promedio obtenida por el MOGA para la topología NSF-14 con carga aleatoria.

FIGURA D.13: Distancia total promedio obtenida por el GA para la topología NSF-14 con carga aleatoria.




FIGURA D.16: Costo total promedio obtenido por el MOGA para la topología NSf-14 con carga aleatoria.

FIGURA D.15: Costo total promedio obtenido por el GA para la topología NSf-14 con carga aleatoria.

D.3. Topología: ARPA-2




FIGURA D.18: Fitness promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.

FIGURA D.17: Fitness promedio obtenido por el GA para la topología ARPA-2 con carga aleatoria.




FIGURA D.19: Máximo FS promedio obtenido por el GA para la topología ARPA-2 con carga aleatoria.




FIGURA D.20: Máximo FS promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.




FIGURA D.22: Distancia total promedio obtenida por el MOGA para la topología ARPA-2 con carga aleatoria.

FIGURA D.21: Distancia total promedio obtenida por el GA para la topología ARPA-2 con carga aleatoria.




FIGURA D.23: Costo total promedio obtenido por el GA para la topología ARPA-2 con carga aleatoria.




FIGURA D.24: Costo total promedio obtenido por el MOGA para la topología ARPA-2 con carga aleatoria.

Referencias

- [AGP10] Nabila Azi, Michel Gendreau y Jean-Yves Potvin. “An exact algorithm for a vehicle routing problem with time windows and multiple use of vehicles”. En: *European Journal of Operational Research* 202.3 (2010), págs. 756-763.
- [Alm+13] RC Almeida y col. “An evolutionary spectrum assignment algorithm for elastic optical networks”. En: *Transparent Optical Networks (ICTON), 2013 15th International Conference on*. 2013, págs. 1-3.
- [Ass+14] KDR Assis y col. “Flexgrid optical networks design under multiple modulation formats”. En: *Telecommunications Symposium (ITS), 2014 International*. IEEE. 2014, págs. 1-5.
- [AW14] Michal Aibin y Krzysztof Walkowiak. “Simulated annealing algorithm for optimization of elastic optical networks with unicast and anycast traffic”. En: *Transparent Optical Networks (ICTON), 2014 16th International Conference on*. IEEE. 2014, págs. 1-4.
- [Bañ06] R Baños. “Meta-heurísticas Híbridas para optimización. Mono-objetivo y Multi-objetivo. Paralelización y Aplicaciones”. Tesis doct. Tesis de Doctorado). Universidad de Almería, 2006.
- [BT95] Tobias Blickle y Lothar Thiele. *A comparison of selection schemes used in genetic algorithms*. 1995.
- [BW98] Peter J Bentley y Jonathan P Wakefield. “Finding acceptable solutions in the pareto-optimal range using multiobjective genetic algorithms”. En: *Soft computing in engineering design and manufacturing*. Springer, 1998, págs. 231-240.

- [Cai+13] Anliang Cai y col. "Novel node-arc model and multiiteration heuristics for static routing and spectrum assignment in elastic optical networks". En: *Journal of Lightwave Technology* 31.21 (2013), págs. 3402-3413.
- [Can04] Santiago Canales Cano. "Métodos Heurísticos en Problemas Geométricos Visibilidad, Iluminación y Vigilancia". Tesis doct. Universidad Politécnica de Madrid, 2004.
- [Cas+12] Alberto Castro y col. "Dynamic routing and spectrum (re) allocation in future flexgrid optical networks". En: *Computer Networks* 56.12 (2012), págs. 2869-2883.
- [CLVV+07] Carlos A Coello Coello, Gary B Lamont, David A Van Veldhuizen y col. *Evolutionary algorithms for solving multi-objective problems*. Vol. 5. Springer, 2007.
- [Coe00a] Carlos A Coello. "An updated survey of GA-based multiobjective optimization techniques". En: *ACM Computing Surveys (CSUR)* 32.2 (2000), págs. 109-143.
- [Coe00b] Carlos A Coello. "An updated survey of GA-based multiobjective optimization techniques". En: *ACM Computing Surveys (CSUR)* 32.2 (2000), págs. 109-143.
- [CR13] João HL Capucho y Leandro C Resendo. "ILP model and effective genetic algorithm for routing and spectrum allocation in elastic optical networks". En: *Microwave & Optoelectronics Conference (IMOC), 2013 SBMO/IEEE MTT-S International*. IEEE. 2013, págs. 1-5.
- [CTV10] Kostas Christodoulopoulos, Ioannis Tomkos y Emmanouel A Varvarigos. "Routing and spectrum allocation in OFDM-based optical networks with elastic bandwidth allocation". En: *Global Telecommunications Conference (GLOBECOM 2010), 2010 IEEE*. IEEE. 2010, págs. 1-6.
- [CTV11] Konstantinos Christodoulopoulos, Ioannis Tomkos y EA Varvarigos. "Elastic bandwidth allocation in flexible OFDM-based optical networks". En: *Journal of Lightwave Technology* 29.9 (2011), págs. 1354-1366.

- [DAR16] Luis Delvalle, Ester Alfonzo y Diego P Pinto Roa. "EONS: An online RSA simulator for elastic optical networks". En: *Computer Science Society (SCCC), 2016 35th International Conference of the Chilean*. IEEE. 2016, págs. 1-12.
- [Ehr06] A Ehrhardt. "Next generation optical networks: An operator's point of view". En: *Transparent Optical Networks, 2006 International Conference on*. Vol. 1. IEEE. 2006, págs. 93-97.
- [Enn+06] K Ennser y col. "Reconfigurable add/drop multiplexer design to implement flexibility in optical networks". En: *Transparent Optical Networks, 2006 International Conference on*. Vol. 3. IEEE. 2006, págs. 74-77.
- [FF+93] Carlos M Fonseca, Peter J Fleming y col. "Genetic Algorithms for Multi-objective Optimization: Formulation Discussion and Generalization." En: *Icga*. Vol. 93. July. 1993, págs. 416-423.
- [Flo11] Susana Duarte Flores. *Optimización Multiobjetivo de redes empleando Algoritmos Evolutivos Paralelos*. 2011.
- [FWK05] Jon Feldman, Martin J Wainwright y David R Karger. "Using linear programming to decode binary linear codes". En: *IEEE Transactions on Information Theory* 51.3 (2005), págs. 954-972.
- [Ger+12] Ori Gerstel y col. "Elastic optical networking: A new dawn for the optical layer?" En: *IEEE Communications Magazine* 50.2 (2012).
- [GKW14] Roza Goscien, Mirosław Klinkowski y Krzysztof Walkowiak. "A tabu search algorithm for routing and spectrum allocation in elastic optical networks". En: *Transparent Optical Networks (ICTON), 2014 16th International Conference on*. IEEE. 2014, págs. 1-4.
- [GM17] Prashant K Gupta y Pranab K Muhuri. "Multi-objective linguistic optimization: Extensions and new directions using 2-tuple fuzzy linguistic representation model". En: *Fuzzy Systems (FUZZ-IEEE), 2017 IEEE International Conference on*. IEEE. 2017, págs. 1-6.
- [GM86] Diaa Gabbani y Michael Magazine. "An interactive heuristic approach for multi-objective integer-programming problems". En: *Journal of the Operational Research Society* (1986), págs. 285-291.

- [GNS00] Nada Golmie, Thomas D Ndousse y David H Su. "A differentiated optical services model for WDM networks". En: *IEEE Communications Magazine* 38.2 (2000), págs. 68-73.
- [Gol06] David E Goldberg. *Genetic algorithms*. Pearson Education India, 2006.
- [Gon+12] Long Gong y col. "A two-population based evolutionary approach for optimizing routing, modulation and spectrum assignments (RMSA) in O-OFDM networks". En: *IEEE Communications letters* 16.9 (2012), págs. 1520-1523.
- [GS02] Ornan Gerstel y Galen Sasaki. "Quality of protection (QoP): a quantitative unifying paradigm to protection service grades". En: *Optical Networks Magazine* 3.3 (2002), págs. 40-49.
- [Hai17] Dao Thanh Hai. "Multi-objective genetic algorithm for solving routing and spectrum assignment problem". En: *Information Science and Technology (ICIST), 2017 Seventh International Conference on*. IEEE. 2017, págs. 177-180.
- [HH17] Dao Thanh Hai y Kha Manh Hoang. "An efficient genetic algorithm approach for solving routing and spectrum assignment problem". En: *Recent Advances in Signal Processing, Telecommunications & Computing (Sig-TelCom), International Conference on*. IEEE. 2017, págs. 187-192.
- [HHM12] Jun Huang, Xiaohong Huang y Yan Ma. "Routing with multiple quality-of-services constraints: an approximation perspective". En: *Journal of Network and Computer Applications* 35.1 (2012), págs. 469-479.
- [Hil+12] David Hillerkuss y col. "Single-laser 32.5 Tbit/s Nyquist WDM transmission". En: *Journal of Optical Communications and Networking* 4.10 (2012), págs. 715-723.
- [HL92] Prabhat Hajela y Chyi-Yeu Lin. "Genetic search strategies in multicriterion optimal design". En: *Structural optimization* 4.2 (1992), págs. 99-107.
- [Jin+09] Masahiko Jinno y col. "Spectrum-efficient and scalable elastic optical path network: architecture, benefits, and enabling technologies". En: *IEEE Communications Magazine* 47.11 (2009).
- [KC11] Mirosław Klinkowski y Davide Careglio. "A routing and spectrum assignment problem in optical OFDM networks". En: *First European Teletraffic Seminar*. 2011.

- [Kli+16] Mirosław Klinkowski y col. "Solving large instances of the RSA problem in flexgrid elastic optical networks". En: *Journal of Optical Communications and Networking* 8.5 (2016), págs. 320-330.
- [Kli13] Mirosław Klinkowski. "A genetic algorithm for solving RSA problem in elastic optical networks with dedicated path protection". En: *International Joint Conference CISIS'12-ICEUTE' 12-SOCO' 12 Special Sessions*. Springer. 2013, págs. 167-176.
- [KW11] Mirosław Klinkowski y Krzysztof Walkowiak. "Routing and spectrum assignment in spectrum sliced elastic optical path network". En: *IEEE Communications Letters* 15.8 (2011), págs. 884-886.
- [KW12] Mirosław Klinkowski y Krzysztof Walkowiak. "Offline RSA algorithms for elastic optical networks with dedicated path protection consideration". En: *Ultra Modern Telecommunications and Control Systems and Workshops (ICUMT), 2012 4th International Congress on*. IEEE. 2012, págs. 670-676.
- [KWJ11] Mirosław Klinkowski, Krzysztof Walkowiak y Marek Jaworski. "Off-line algorithms for routing, modulation level, and spectrum assignment in elastic optical networks". En: *Transparent Optical Networks (ICTON), 2011 13th International Conference on*. IEEE. 2011, págs. 1-6.
- [Ler+13] Arturo Mayoral López de Lerma y col. "Algoritmos de planificación para redes elásticas". B.S. thesis. 2013.
- [Lez+16] Fernando Lezama y col. "Differential evolution optimization applied to the routing and spectrum allocation problem in flexgrid optical networks". En: *Photonic Network Communications* 31.1 (2016), págs. 129-146.
- [LG12] Junyan Liu y Wanyi Gu. "Spectrum consecutiveness based routing and spectrum allocation in flexible bandwidth networks". En: *Chinese Optics Letters* (2012).
- [LK15] Bingbing Li y Young-Chon Kim. "Efficient routing and spectrum allocation considering QoT in elastic optical networks". En: *Telecommunications and Signal Processing (TSP), 2015 38th International Conference on*. IEEE. 2015, págs. 109-112.

- [Mar17] Goran Z Marković. “Routing and spectrum allocation in elastic optical networks using bee colony optimization”. En: *Photonic Network Communications* (2017), págs. 1-19.
- [Mie99] Kaisa Miettinen. *Nonlinear Multiobjective Optimization, volume 12 of International Series in Operations Research and Management Science*. 1999.
- [Muh17] Prashant K Gupta; Pranab K. Muhuri. *Multi-objective linguistic optimization: Extensions and new directions using 2-tuple fuzzy linguistic representation model*. 2017.
- [Muk06] Biswanath Mukherjee. *Optical WDM networks*. Springer Science & Business Media, 2006.
- [MZ12] Zuqing Zhu Yawei Yin S. J. Ben Yoo Mingyang Zhang Lu Wei. *Planning and Provisioning of Elastic O-OFDM Networks with Fragmentation-Aware Routing and Spectrum Assignment (RSA) Algorithms*. 2012.
- [Nar08] Giuseppe Narzisi. *Classic Methods for Multi-Objective Optimization*. 2008.
- [NBPR07] Carlos Núñez, Benjamín Barán y DP Pinto-Roa. “Asignación óptima de Lightpath bajo requerimientos de QoS. Un enfoque multiobjetivo basado en MOEAs”. En: *XXXIII Conferencia Latinoamericana en Informática CLEI*. Vol. 2007. 2007.
- [OFP16] Ysapy Mimbi Ortiz, Carmelo Fretes y Diego P. Pinto. “Routing and Spectrum Allocation in Elastic Networks. An approach based on Multi-objective Evolutionary Algorithms”. En: *5th International Conference on Engineering Optimization (ENGOPT)*. Federal University of Rio de Janeiro. 2016.
- [OG12] Andrew Lord S.J. Ben Yoo Ori Gerstel Masahiko Jinno. *Elastic optical networking: a new dawn for the optical layer?* 2012.
- [OP17] Ysapy Mimbi Ortiz y Diego P. Pinto. “Routing and Spectrum Allocation in Elastic Optical Networks based on Multi-Objective Genetic Algorithm”. En: *37 Congreso Nacional de Matemática Aplicada y Computacional (CN-MAC)*. Sociedade Brasileira de Matemática Aplicada e Computacional. 2017.
- [Pat+11a] Ankitkumar N Patel y col. “Survivable transparent flexible optical WDM (FWDM) networks”. En: *Optical Fiber Communication Conference*. Optical Society of America. 2011, OTuI2.

- [Pat+11b] Ankitkumar N Patel y col. “Survivable transparent flexible optical WDM (FWDM) networks”. En: *Optical Fiber Communication Conference*. Optical Society of America. 2011, OTuI2.
- [Ped+12] O Pedrola y col. “CAPEX study for a multilayer IP/MPLS-over-flexgrid optical network”. En: *Journal of Optical Communications and Networking* 4.8 (2012), págs. 639-650.
- [Puj12] Isaac Seoane Pujol. “Contribución al diseño de redes ópticas de nueva generación: protección, calidad de servicio y eficiencia energética”. Tesis doct. Universidad Carlos III de Madrid, 2012.
- [RBPR14] Marcelo D Rodas-Brítez y Diego P Pinto-Roa. “Quality of protection on WDM networks: A quantitative paradigm based on recovery probability”. En: *Computing Conference (CLEI), 2014 XL Latin American*. IEEE. 2014, págs. 1-11.
- [Rec12] G Recommendation. “694.1: Spectral grids for WDM applications: DWDM frequency grid”. En: *International Telecommunications Union, Tech. Rep* (2012).
- [RKW09] Jong-hyun Ryu, Sujin Kim y Hong Wan. “Pareto front approximation with adaptive weighted sum method in multiobjective simulation optimization”. En: *Winter Simulation Conference*. Winter Simulation Conference. 2009, págs. 623-633.
- [Ros70] Richard S Rosenberg. “Stimulation of genetic populations with biochemical properties: I. the model”. En: *Mathematical Biosciences* 7.3-4 (1970), págs. 223-257.
- [RR09] Singiresu S Rao y Singiresu S Rao. *Engineering optimization: theory and practice*. John Wiley & Sons, 2009.
- [Sch98] Alexander Schrijver. *Theory of linear and integer programming*. John Wiley & Sons, 1998.
- [SD94] Nidamarthi Srinivas y Kalyanmoy Deb. “Muultiobjective optimization using nondominated sorting in genetic algorithms”. En: *Evolutionary computation* 2.3 (1994), págs. 221-248.
- [Sim13] Dan Simon. *Evolutionary optimization algorithms: biologically-inspired and population-based approaches to computer intelligence*. Hoboken. 2013.

- [SN99] VDaisuke Maruhashi VKazuo Yamane VHiroyasu Sumiya y VYasuo Nagai. "WDM optical fiber transmission systems". En: *FUJITSU Sci. Tech. J* 35.1 (1999), págs. 25-33.
- [Som06] Arun Somani. *Survivability and traffic grooming in WDM optical networks*. Cambridge University Press, 2006.
- [Tak+10] T Takagi y col. "Algorithms for maximizing spectrum efficiency in elastic optical path networks that adopt distance adaptive modulation". En: *Optical Communication (ECOC), 2010 36th European Conference and Exhibition on*. IEEE. 2010, págs. 1-3.
- [Tal+15] Sahar Talebi y col. "On routing and spectrum assignment in rings". En: *Journal of Lightwave Technology* 33.1 (2015), págs. 151-160.
- [Tan03] Andrew S Tanenbaum. *Redes de computadoras*. Pearson Educación, 2003.
- [Tri+16] CL Triveni y col. "Routing and spectrum allocation in SLICE optical networks". En: *Electrical, Electronics, Communication, Computer and Optimization Techniques (ICEECCOT), 016 International Conference on*. IEEE. 2016, págs. 119-122.
- [Vel+12] Luis Velasco y col. "Modeling the routing and spectrum allocation problem for flexgrid optical networks". En: *Photonic Network Communications* 24.3 (2012), págs. 177-186.
- [Wan+12a] Yang Wang y col. "Towards elastic and fine-granular bandwidth allocation in spectrum-sliced optical networks". En: *Journal of Optical Communications and Networking* 4.11 (2012), págs. 906-917.
- [Wan+12b] Ying Wang y col. "Routing and spectrum assignment by means of ant colony optimization in flexible bandwidth networks". En: *National Fiber Optic Engineers Conference*. Optical Society of America. 2012, NTu2J-3.
- [Wan+13] Ying Wang y col. "ACO-based routing and spectrum allocation in flexible bandwidth networks". En: *Photonic Network Communications* 25.3 (2013), págs. 135-143.
- [WCP11] Yang Wang, Xiaojun Cao y Yi Pan. "A study of the routing and spectrum allocation in spectrum-sliced elastic optical path networks". En: *INFOCOM, 2011 Proceedings IEEE*. IEEE. 2011, págs. 1503-1511.

- [WKG13] Krzysztof Walkowiak, Roza Goscien y Mirosław Klinkowski. “On minimization of the spectrum usage in elastic optical networks with joint unicast and anycast traffic”. En: *Asia Communications and Photonics Conference*. Optical Society of America. 2013, AF4G-1.
- [Win09] Peter J Winzer. “Modulation and multiplexing in optical communication systems”. En: *IEEE Leos Newsletter* 23.1 (2009), págs. 4-10.
- [WK13a] Krzysztof Walkowiak y Mirosław Klinkowski. “Joint anycast and unicast routing for elastic optical networks: Modeling and optimization”. En: *Communications (ICC), 2013 IEEE International Conference on*. IEEE. 2013, págs. 3909-3914.
- [WK13b] Krzysztof Walkowiak y Mirosław Klinkowski. “Shared backup path protection in elastic optical networks: Modeling and optimization”. En: *Design of Reliable Communication Networks (DRCN), 2013 9th International Conference on the*. IEEE. 2013, págs. 187-194.
- [WMM14] Feng Wang, Yuan Man y Lichun Man. “Intelligent optimization approach for the k shortest paths problem based on genetic algorithm”. En: *Natural Computation (ICNC), 2014 10th International Conference on*. IEEE. 2014, págs. 219-224.
- [WPL15] Paul Wright, Michael C Parker y Andrew Lord. “Minimum-and maximum-entropy routing and spectrum assignment for flexgrid elastic optical networking”. En: *Journal of Optical Communications and Networking* 7.1 (2015), A66-A72.
- [ZDLM12] Guoying Zhang, Marc De Leenheer y Biswanath Mukherjee. “Optical traffic grooming in OFDM-based elastic optical networks”. En: *Journal of Optical Communications and Networking* 4.11 (2012), B17-B25.
- [Zha+11] Fatai Zhang y col. “Requirements for GMPLS control of flexible grids”. En: *IETF Internet Draft* 1 (2011).
- [Zha+13] Guoying Zhang y col. “A survey on OFDM-based elastic core optical networking”. En: *IEEE Communications Surveys & Tutorials* 15.1 (2013), págs. 65-87.

- [Zhe+10] Wei Zheng y col. “On the spectrum-efficiency of bandwidth-variable optical OFDM transport networks”. En: *Optical Fiber Communication (OFC), collocated National Fiber Optic Engineers Conference, 2010 Conference on (OFC/NFOEC)*. IEEE. 2010, págs. 1-3.